



UNIVERSITÉ DE TUNIS
INSTITUT SUPÉRIEUR DE GESTION DE TUNIS

Rapport de Projet de Fin d'Études
En vue de l'obtention du diplôme de Master professionnel
Spécialité : Data Science for Business

Entreprise d'accueil :



Détection des transactions bancaires suspectes
basée sur l'intelligence artificielle

Réalisé par :

Ben Rbiha Yassine

Encadrant académique

M. Chaker Katar

Encadrant professionnel

M. Noomen Habassi

Année Universitaire 2025 / 2026

aa

Dédicace

À la mémoire de mon père **Mounir**,

Que ton âme repose en paix. Tu resteras à jamais dans mon cœur, et c'est pour toi que je continue d'avancer.

À ma mère **Fadhila**,

Pour ton amour inconditionnel, tes sacrifices et ton soutien sans faille tout au long de mon parcours. Ce travail est le fruit de ta confiance et de ta bienveillance.

À moi-même,

Pour avoir avancé malgré les doutes, surmonté les obstacles, et gardé en moi l'envie d'y croire. Pour chaque effort silencieux, chaque victoire intime, et chaque moment de courage discret.

À mes deux frères **Khalil** et **Ahmed**,

Pour votre présence, votre soutien et votre complicité qui ont illuminé chaque étape de ce parcours.

À mes tantes,

Pour leur soutien indéfectible, leur générosité et leur présence précieuse tout au long de ce parcours. Votre amour et vos encouragements ont été une source de force et de motivation tout au long de ce chemin.

À ma grand-mère **Jalila**,

Que Dieu vous accorde longue vie, bonne santé et bonheur. Votre amour et vos prières ont été ma plus grande force tout au long de ce parcours.

À mon oncle **Nabil**,

Ton soutien inoubliable, ta générosité et ta bienveillance ont été d'un précieux réconfort tout au long de ce parcours. Les mots ne suffisent pas à exprimer la gratitude que je te porte.

À mes amis,

Pour les moments partagés, les encouragements mutuels et la bonne humeur qui ont rendu ce parcours plus léger.

*Merci à tous d'avoir été mes piliers et d'avoir cru en moi.
Cette réussite vous appartient autant qu'elle m'appartient...*

Table des matières

Table des figures	vi
Liste des tableaux	vii
Liste des acronymes	1
Introduction Générale	2
Chapitre 1 : Cadre général et contexte du projet	4
1 Introduction	4
1.1 Présentation de la BH Bank	4
1.1.1 Les valeurs de la BH Bank	4
1.1.2 La vision de la BH Bank	4
1.1.3 Mission de la BH Bank	5
1.1.4 Organisation de la Banque	6
1.2 Description du projet	6
1.3 Etude de l'existant	6
1.3.1 Problématique	7
1.3.2 Solution proposée	7
1.3.3 Méthodologies de gestion de projet	7
1.3.4 Présentation de la méthodologie agile	7
1.3.5 Présentation de la méthodologie CRISP-DM	7
1.3.6 Choix de la méthodologie de travail	8
1.4 Méthodologie CRISP-DM	8
1.5 Conclusion	10
Chapitre 2 : Concepts fondamentaux et compréhension métier	11
2.1 Introduction	11
2.2 Concepts fondamentaux	11
2.2.1 Évolution des fraudes bancaires à l'ère de la digitalisation	11
2.2.2 Contexte des anomalies dans les transactions bancaires en Tunisie	12
2.2.3 Types d'anomalies dans les transactions bancaires	12
2.2.4 Impact économique et social	14
2.2.5 Indicateurs de suspicion transactionnelle	14
2.2.6 Rôle stratégique de l'Intelligence Artificielle dans la suspicion d'anomalies transactionnelles	15
2.2.7 Exploitation du machine learning dans le cadre de la suspicion et de la prévention de la fraude	18
2.2.8 Notion d'anomalie vs fraude	18
2.3 Détection des schémas suspects	19
2.4 Sécurité et conformité réglementaire	19
2.4.1 Renforcement de la sécurité	19
2.4.2 Impact économique et durable	20
2.5 Compréhension métier	20
2.5.1 Objectifs du projet	20

2.5.2	Étapes principales du projet	21
2.5.3	Outils utilisés	21
2.6	Conclusion	22
Chapitre 3 : Compréhension et préparation des données		23
3.1	Introduction	23
3.2	Compréhension des données	24
3.2.1	Description générale	24
3.2.2	Structure des données brutes	24
3.2.3	Scénarios de fraude identifiés	24
3.2.4	Structure et description des variables du dataset	25
3.2.5	Analyse exploratoire des données (EDA)	29
3.3	Préparation des données	33
3.3.1	Chargement des données	34
3.3.2	Prétraitement des données	35
3.3.3	Construction des caractéristiques	37
3.3.4	Sélection des caractéristiques	38
3.4	Conclusion	40
Chapitre 4 : Modélisation		42
4.1	Introduction	42
4.2	Modélisation	42
4.2.1	Approche supervisée	42
4.2.1.1	Métriques d'évaluation des modèles supervisés	48
4.2.1.2	Score composite des modèles supervisés	50
4.2.1.3	Résultats de l'évaluation des modèles supervisés	50
4.2.1.4	Interprétabilité du modèle XGBoost avec SHAP	51
4.2.2	Approche non supervisée	53
4.2.2.1	Métriques d'évaluation des modèles non supervisés	60
4.2.2.2	Score composite pour les modèles non supervisés	61
4.2.2.3	Résultats de la sélection par score composite	62
4.2.3	Modèles de Deep Learning	62
4.2.3.1	Choix des modèles de Deep Learning	63
4.2.4	Synthèse comparative des trois approches de modélisation	66
4.3	Conclusion	67
Chapitre 5 : Déploiement de la solution		68
5.1	Introduction	68
5.2	Technologies et outils utilisés	68
5.3	Analyse fonctionnelle des pages de l'interface web	69
5.3.1	Page d'accueil	69
5.3.2	Page de simulation	70
5.3.3	Page Chatbot	73
5.3.4	Page du dashboard	76
5.4	Conclusion	77
Références		79

Table des figures

1.1	Chiffres de l'année 2023 (BH Bank)	5
1.2	Logo BH bank[1]	5
1.3	Organigramme du BH bank	6
1.4	La méthodologie CRISP-DM[2]	9
2.1	Composantes de l'IA [3]	15
2.2	Approche supervisée [4]	17
2.3	Approche non supervisée[5]	17
3.1	Matrice de corrélation des variables	30
3.2	Analyse univariée des variables	32
3.3	Comportement anormal d'un compte	33
3.4	Informations générales	35
3.5	Nettoyage des données	36
3.6	Normalisation des données	36
3.7	Distribution des classes avant et après application de SMOTE	37
3.8	Exemple des caractéristiques	38
3.9	Sélection par MI	39
3.10	Nombre de variables sélectionnées par MI avant et après filtrage de corrélation	40
4.1	Schéma de l'approche supervisée pour la classification des transactions bancaires	43
4.2	Importance globale des variables avec SHAP	52
4.3	Explication locale avec SHAP Waterfal	53
4.4	Approche non supervisée	54
4.5	Projection PCA 2D des résultats K-Means	55
4.6	Scores d'anomalie obtenus par Isolation Forest	56
4.7	Distribution des scores de décision du modèle One-Class SVM	57
4.8	Répartition des comptes normaux et suspects	58
4.9	Distribution des distances au centroïde	59
4.10	L'évolution de l'AUC sur l'ensemble de validation	63
4.11	Top 10 des features les plus importantes selon TabNet	64
4.12	Courbe de loss de l'Autoencoder	65
5.1	Page d'accueil de l'application	69
5.2	Interface des principales fonctionnalités de la page d'accueil	70
5.3	Saisie manuelle de transactions d'un compte	71
5.4	Interface de la page de simulation en mode import de fichier	72
5.5	Résultat de l'analyse après import du fichier	72
5.6	Interface du chatbot en mode texte	74
5.7	Activation du mode vocal du chatbot	75
5.8	Réponse du chatbot après interaction vocale	76
5.9	Analyse exploratoire des données par PowerBI	77

Liste des tableaux

3.1	Description des variables du fichier <code>opérations_comptes.xls</code>	26
3.2	Description des variables du fichier <code>features_comptes.xlsx</code>	28
4.1	Comparaison des modèles supervisés selon les métriques et le score composite	50
4.2	Tableau de comparaison des métriques pour les modèles non supervisés	62

Liste des acronymes

CRISP-DM	Cross-Industry Standard Process for Data Mining
IA	Intelligence Artificielle
ML	Machine Learning
DL	Deep Learning
XGBoost	Extreme Gradient Boosting
RF	Random Forest
SVM	Support Vector Machine
KNN	K-Nearest Neighbors
LOF	Local Outlier Factor
BIRCH	Balanced Iterative Reducing and Clustering using Hierarchies
EDA	Exploratory Data Analysis
PCA	Principal Component Analysis
MI	Mutual Information
SMOTE	Synthetic Minority Over-sampling Technique
TP	True Positives
FP	False Positives
FN	False Negatives
ROC	Receiver Operating Characteristic
AUC	Area Under the Curve
ROC-AUC	Area Under the Receiver Operating Characteristic Curve
RAG	Retrieval-Augmented Generation
NLP	Natural Language Processing
LLM	Large Language Model
DAB	Distributeur Automatique de Billets
TPE	Terminal de Paiement Électronique
API	Application Programming Interface
REST	Representational State Transfer

Introduction Générale

Avec la transformation digitale et l'essor des technologies numériques, le secteur bancaire connaît des mutations profondes qui redéfinissent ses modes de fonctionnement. Si ces évolutions offrent de nouvelles opportunités en matière de services et de performance, elles s'accompagnent également de risques croissants liés aux transactions suspectes et aux comportements frauduleux. Ces derniers peuvent prendre diverses formes : opérations de montants inhabituels, vitesse géographique anormale, activité nocturne atypique, ou encore structuration de paiements visant à contourner les mécanismes de surveillance. Dans tous les cas, les conséquences sont lourdes : pertes financières significatives, atteinte à la réputation des institutions, et exposition à des sanctions réglementaires.

La Tunisie n'échappe pas à cette problématique. Les banques locales doivent faire face à des comportements transactionnels de plus en plus complexes, dans un environnement marqué par une intensification des échanges numériques et par une exigence accrue de conformité aux standards internationaux. Les méthodes traditionnelles de détection, basées sur des règles statiques ou des seuils prédéfinis, montrent rapidement leurs limites face à la diversité des schémas suspects, qui évoluent constamment et s'adaptent aux dispositifs de contrôle existants.

C'est dans ce contexte critique que s'inscrit le présent projet, réalisé au sein de la BH Bank. L'objectif principal est de concevoir et de mettre en place un système intelligent de détection des transactions suspectes, reposant sur les technologies de l'intelligence artificielle et de l'apprentissage automatique, afin d'analyser les comportements transactionnels des comptes bancaires et d'identifier automatiquement les schémas inhabituels susceptibles de représenter un risque.

En complément, une interface interactive intégrant un assistant conversationnel basé sur des modèles de langage avancés a été développée, permettant de faciliter l'accès à l'information et d'accompagner l'utilisateur dans l'interprétation des résultats.

Au-delà de la dimension technique, ce projet contribue à renforcer la confiance dans les institutions financières tunisiennes en proposant un outil complet et opérationnel, capable d'assister les analystes bancaires dans leurs décisions et de renforcer durablement les capacités de surveillance transactionnelle de la BH Bank.

Ce projet est structuré en quatre chapitres comme suit :

Chapitre 1 : Cadre général et contexte du projet. Ce chapitre présente le cadre général du projet en introduisant la BH Bank, son organisation et ses activités. Il expose le contexte global lié aux anomalies transactionnelles dans le secteur bancaire tunisien, définit la problématique, les objectifs du projet, puis détaille la méthodologie CRISP-DM adoptée pour structurer l'ensemble de la démarche.

Chapitre 2 : Concepts fondamentaux et compréhension métier. Ce chapitre établit les bases théoriques et méthodologiques nécessaires à la détection des transactions suspectes. Il décrit les différentes typologies d'anomalies bancaires, leurs impacts sur le secteur financier, ainsi que l'apport de l'intelligence artificielle dans ce domaine.

Il aborde également la phase de compréhension métier de la méthodologie CRISP-DM, permettant de définir le cadre analytique, les scénarios de fraude identifiés et les indicateurs de suspicion retenus.

Chapitre 3 : Compréhension et préparation des données. Ce chapitre traite des phases d'exploration et de préparation des données transactionnelles réelles issues de la BH Bank. Il présente la structure des fichiers de données, l'analyse exploratoire, ainsi que les étapes de nettoyage, de normalisation et de construction des caractéristiques comportementales par feature engineering, constituant le jeu de données final utilisé pour la modélisation.

Chapitre 4 : Modélisation et déploiement de la solution. Ce chapitre couvre les phases de modélisation et de mise en production du système. La modélisation repose sur une combinaison d'approches supervisées, non supervisées ainsi que des techniques de *deep learning*, permettant d'analyser efficacement les comportements transactionnels et de détecter les anomalies.

La phase de déploiement décrit le développement d'un système intelligent sous forme d'une application web, intégrant un module de simulation des transactions, un assistant conversationnel basé sur une architecture RAG, ainsi que des outils de visualisation analytique. L'ensemble constitue une solution interactive d'aide à la décision destinée aux analystes bancaires.

Chapitre 1 : Cadre général et contexte du projet

1 Introduction

Dans le cadre de ce projet de fin d'études, ce premier chapitre a pour objectif de présenter le contexte général dans lequel s'inscrit notre travail. Nous commençons par introduire la BH Bank, son organisation et ses missions, afin de mieux appréhender l'environnement métier du projet. Nous exposons ensuite la problématique identifiée, la solution proposée, ainsi que la méthodologie adoptée pour structurer notre démarche analytique, à savoir CRISP-DM.

1.1 Présentation de la BH Bank

La BH Bank est une banque tunisienne de premier plan, historiquement impliquée dans le développement économique national. Régie par la loi relative aux établissements de crédit, elle est dédiée à la satisfaction de sa clientèle et à l'innovation dans les services financiers. Depuis la transformation du CNEL en banque en 1989, le modèle d'affaires de la BH Bank est devenu celui d'une banque universelle, avec pour mission principale de proposer un éventail complet de solutions financières à toutes les catégories de clients, des particuliers aux entreprises. Depuis 1993, elle opère comme un groupe financier intégré, combinant diverses activités telles que l'assurance, le leasing et le capital-investissement. Avec 11 filiales, un réseau de 150 agences à travers la Tunisie et un portefeuille de plus de 780 000 clients, la BH Bank s'affirme comme une banque de référence dans le pays. Elle ne cesse d'améliorer ses services et de multiplier ses atouts pour offrir une expérience client de qualité. Grâce à son investissement dans les technologies de pointe et l'optimisation de ses ressources humaines, la BH Bank a su évoluer pour répondre aux besoins spécifiques de sa clientèle. Elle s'est ainsi imposée comme un acteur clé du paysage bancaire tunisien, s'engageant fermement en faveur de la croissance durable et de la transparence dans ses opérations. Cet engagement est un facteur déterminant de sa solidité financière et de sa pérennité.

1.1.1 Les valeurs de la BH Bank

La BH Bank prône des valeurs d'excellence, d'engagement et de coopération. En tant que groupe financier intégré, elle vise à renforcer la qualité de ses services tout en créant un environnement de travail favorable à l'épanouissement personnel et professionnel de ses collaborateurs. La banque se distingue par son esprit d'innovation et son engagement à l'égard de ses clients.

1.1.2 La vision de la BH Bank

BH capitalise ainsi sur son expertise et son savoir-faire cumulés au cours de ses 40 ans d'existence, à travers une vision stratégique globale de 3 axes :

- **Fidélisation du client** : grâce à la digitalisation, l'innovation par l'Usage et la création de la Valeur- Client
- **Optimisation et efficacité opérationnelle** : via l'automatisation des processus, l'intégration des outils digitaux et la standardisation des services récurrents.

- **Croissance saine, Conforme et rentable** : à travers un équipement optimal, une valorisation de la fonction conseil, une segmentation affinée, une vision 360°, un gain en écrémage et un accroissement du pnb.




FIGURE 1.1 – Chiffres de l'année 2023 (BH Bank)

1.1.3 Mission de la BH Bank

Ancré dans le paysage financier tunisien depuis des décennies, la BH Bank poursuit son plan de transformation tout en mettant le client au centre de sa stratégie pour mieux accomplir ses missions d'une stratégie monétaire évolutive, d'une stabilité financière et d'un service économique mieux adapté à la collectivité.



FIGURE 1.2 – Logo BH bank[1]

1.1.4 Organisation de la Banque

- **Le Pôle moyens et support** : Comprend la gestion des ressources humaines, la gestion des achats et logistiques, la comptabilité, l'organisation et la maîtrise d'ouvrage ainsi que l'infrastructure et la sécurité du système informatique.
- **Le pôle opération** : Regroupe le back office bancaire, le bancaire étranger, le recouvrement et contentieux, les affaires juridiques et la gestion administrative des crédits.
- **Le Pôle risque et crédits** : Comme son nom l'indique, c'est le pôle chargé de l'analyse des crédits et leur résolution ainsi que de la gestion des différents risques : crédits, marché et opérationnels
- **Le pôle commercial** : C'est le pôle qui gère toute l'activité commerciale des différents marchés de la banque.




FIGURE 1.3 – Organigramme du BH bank

1.2 Description du projet

Ce projet s'inscrit dans le cadre de l'analyse des données transactionnelles bancaires et vise à contribuer à la détection de comportements atypiques et potentiellement frauduleux à partir des opérations réalisées par les clients.

1.3 Etude de l'existant

Dans un contexte bancaire marqué par une augmentation continue du volume des transactions et par la diversification des canaux de paiement, les méthodes traditionnelles de surveillance basées sur des règles fixes montrent leurs limites. Il devient alors nécessaire de recourir à des approches plus intelligentes capables d'analyser les comportements globaux des comptes et d'identifier automatiquement des schémas inhabituels.

1.3.1 Problématique

Notre problématique s’articule autour de la détection de comportements transactionnels anormaux à l’aide des techniques de data science et de l’intelligence artificielle, un enjeu majeur pour les institutions financières, notamment dans le contexte tunisien. La multiplication et la complexité croissante des opérations bancaires rendent les méthodes traditionnelles de contrôle, basées sur des règles fixes, insuffisantes pour identifier efficacement les comportements frauduleux ou atypiques.

En l’absence de données étiquetées fiables, la détection des fraudes bancaires devient un défi important, exposant les banques à des pertes économiques significatives ainsi qu’à des risques de non-conformité réglementaire. Il devient alors nécessaire de développer des solutions fondées sur des approches intelligentes capables d’analyser le comportement global des comptes plutôt que des transactions isolées.

1.3.2 Solution proposée

La solution proposée repose sur une approche de détection d’anomalies non supervisée basée sur l’analyse comportementale des comptes. Elle consiste à effectuer un travail approfondi de feature engineering afin de construire des indicateurs représentatifs des dimensions temporelles, financières et géographiques, puis à appliquer des algorithmes de détection d’anomalies pour identifier les comptes présentant des comportements atypiques. Les résultats sont ensuite interprétés à l’aide d’une logique métier afin de faciliter la prise de décision.

1.3.3 Méthodologies de gestion de projet

Cette section présente les principales méthodologies pouvant encadrer un projet de data science et explique leur importance dans l’organisation du travail. Elle permet de comprendre comment le choix d’une approche adaptée influence la qualité des livrables, l’efficacité du processus et la réussite du projet.

1.3.4 Présentation de la méthodologie agile

La méthodologie Agile est une approche flexible et itérative de la gestion de projet qui met l’accent sur la collaboration, la livraison continue et l’adaptabilité. Elle valorise les personnes, les retours clients et les solutions fonctionnelles plutôt que les processus rigides et la documentation. Pour obtenir des résultats optimaux, les équipes adaptent les pratiques Agile à leurs besoins spécifiques, combinant souvent des frameworks tels que Scrum et Kanban.[6]

Bien que ces méthodologies soient efficaces pour coordonner des projets complexes et dynamiques, elles ne fournissent pas de cadre spécifique pour le traitement des données ou la création de modèles analytiques.

1.3.5 Présentation de la méthodologie CRISP-DM

CRISP-DM ou Cross-Industry Standard Process for Data Mining, est un modèle de processus qui permet d’orienter les travaux d’exploration de données en data science. Cette méthodologie itérative, utilisée par nos data scientist, permet de travailler en

cycles : du business understanding pour comprendre le besoin client jusqu'à l'évaluation où l'équipe présente les résultats aux clients et le déploiement. Cette méthode permet de donner un cadre structuré pour guider les data scientist tout au long du cycle de vie d'un projet[7]

1.3.6 Choix de la méthodologie de travail

Dans le cadre du projet de détection des comportements frauduleux ou atypiques, la méthodologie CRISP-DM a été retenue comme cadre méthodologique principal. Ce choix s'explique par la nature du projet, qui nécessite à la fois une analyse approfondie de données transactionnelles complexes et la mise en œuvre de techniques de modélisation non supervisées. CRISP-DM propose une démarche structurée et progressive permettant de couvrir l'ensemble des étapes, depuis la compréhension du problème métier jusqu'à l'évaluation des résultats et leur interprétation. Contrairement aux méthodologies orientées développement logiciel, CRISP-DM est particulièrement adaptée aux projets de data science, car elle met l'accent sur la qualité analytique, la cohérence des modèles et la pertinence des résultats par rapport aux objectifs métier. Cette approche permet ainsi d'assurer une maîtrise globale et méthodique du processus de réalisation du projet.

1.4 Méthodologie CRISP-DM

La méthodologie CRISP-DM (Cross-Industry Standard Process for Data Mining) constitue un cadre méthodologique structuré et largement adopté pour la conduite des projets de data science et d'exploration de données. Elle propose une approche systématique permettant d'organiser les différentes activités d'un projet tout en assurant une cohérence entre les objectifs métier et les solutions analytiques développées. Le cycle de vie de CRISP-DM est composé de six phases interdépendantes et itératives, permettant des retours en arrière lorsque cela est nécessaire afin d'améliorer la qualité des résultats obtenus.




FIGURE 1.4 – La méthodologie CRISP-DM[2]

1. **Compréhension du métier (Business Understanding)** Cette première phase vise à analyser le contexte organisationnel et à définir clairement le problème à résoudre. Elle constitue le fondement stratégique du projet. Elle comprend notamment :
 - a) Définition des objectifs métier : identifier les enjeux, les besoins des parties prenantes et les résultats attendus.
 - b) Analyse de la situation actuelle : examiner les ressources disponibles, les contraintes techniques, juridiques ou organisationnelles.
 - c) Traduction en objectifs analytiques : transformer les objectifs métier en objectifs de data mining précis et mesurables.
2. **Compréhension des données (Data Understanding)** Cette phase consiste à collecter et analyser les données afin d'en comprendre la structure, la qualité et le potentiel informatif. Elle inclut :
 - a) Collecte des données initiales : rassemblement des données issues de différentes sources internes ou externes.
 - b) Description des données : analyse des types de variables, des distributions et des statistiques descriptives.
 - c) Exploration des données : identification de tendances, corrélations ou anomalies à l'aide de visualisations et d'analyses statistiques.
 - d) Vérification de la qualité des données : détection des valeurs manquantes, incohérences ou données aberrantes.

3. **Préparation des données (Data Preparation)** Cette étape transforme les données brutes en un jeu de données exploitable pour la modélisation. Elle est souvent la plus longue et la plus technique. Elle comprend :
 - a) Sélection des données pertinentes selon les objectifs du projet.
 - b) Nettoyage des données (gestion des valeurs manquantes, suppression des doublons, correction des erreurs).
 - c) Transformation des données (normalisation, encodage, agrégation, création de nouvelles variables).
 - d) Formatage final pour assurer la compatibilité avec les outils de modélisation.
4. **Modélisation (Modeling)** Cette phase consiste à choisir, entraîner et optimiser les algorithmes adaptés au problème étudié. Elle comprend :
 - a) Sélection des techniques de modélisation (supervisées ou non supervisées).
 - b) Construction des modèles à partir des données préparées.
 - c) Réglage des hyperparamètres afin d'optimiser les performances.
 - d) Validation des modèles à l'aide de méthodes appropriées (validation croisée, jeu de test).
5. **Évaluation (Evaluation)** L'objectif de cette phase est de vérifier que le modèle répond aux attentes métier et qu'il apporte une réelle valeur ajoutée. Elle inclut :
 - a) Mesure des performances à l'aide d'indicateurs adaptés.
 - b) Validation métier en collaboration avec les parties prenantes.
 - c) Comparaison des modèles pour sélectionner la meilleure solution.
 - d) Décision finale concernant le passage au déploiement ou le retour à une phase précédente.
6. **Déploiement (Deployment)** Cette dernière phase vise à intégrer le modèle dans l'environnement opérationnel de l'entreprise. Elle comprend :
 - a) Intégration technique du modèle dans les systèmes existants.
 - b) Surveillance et maintenance pour assurer sa performance dans le temps.
 - c) Communication des résultats via des rapports ou tableaux de bord facilitant la prise de décision.

Ainsi, CRISP-DM offre un cadre méthodologique rigoureux et flexible, favorisant une démarche structurée, itérative et alignée sur les objectifs stratégiques de l'organisation.

1.5 Conclusion

Ce chapitre a permis de poser le cadre général du projet en présentant la BH Bank et son environnement organisationnel, ainsi que la problématique liée à la détection des comportements transactionnels atypiques. Face aux limites des méthodes de contrôle traditionnelles, une approche intelligente basée sur l'analyse comportementale des comptes et les techniques de data science a été proposée. La méthodologie CRISP-DM a été retenue comme cadre de travail, grâce à sa rigueur et son adéquation aux projets d'analyse de données. Le chapitre suivant sera consacré aux concepts fondamentaux et à la compréhension métier nécessaires à la réalisation de ce projet.

Chapitre 2 : Concepts fondamentaux et compréhension métier

2.1 Introduction

Ce chapitre présente le cadre conceptuel et méthodologique du projet, centré sur la suspicion d'anomalies dans les transactions bancaires dans un environnement professionnel. L'objectif n'est pas uniquement d'identifier des irrégularités techniques, mais de comprendre les comportements transactionnels atypiques pouvant indiquer un risque potentiel. Cette approche s'inscrit dans une logique préventive d'aide à la décision et de surveillance.

2.2 Concepts fondamentaux

Cette section définit les notions essentielles nécessaires à la compréhension du projet. Elle commence par présenter le contexte des anomalies transactionnelles et des opérations suspectes, en décrivant leurs caractéristiques, leurs mécanismes et leurs formes les plus fréquentes. Une distinction est faite entre les anomalies d'origine externe et celles d'origine interne, tout en soulignant leurs conséquences financières, opérationnelles et réglementaires.

La section met ensuite l'accent sur l'approche par la suspicion, qui repose sur l'analyse de comportements inhabituels, de schémas transactionnels atypiques et d'indicateurs de risque, plutôt que sur une classification binaire immédiate. Dans ce cadre, les méthodes d'analyse de données et d'apprentissage automatique constituent des outils d'assistance permettant de prioriser les alertes et d'orienter les investigations.

Enfin, les aspects liés à la sécurité des systèmes financiers et à la conformité réglementaire sont abordés, car ils jouent un rôle central dans les dispositifs de surveillance transactionnelle. L'intégration de mécanismes analytiques avancés contribue ainsi à améliorer la capacité de contrôle, la réactivité opérationnelle et la robustesse globale du dispositif bancaire.

2.2.1 Évolution des fraudes bancaires à l'ère de la digitalisation

Les fraudes bancaires évoluent à une vitesse alarmante, tirant parti de la digitalisation massive des services financiers. Dans un secteur où les paiements en ligne sont devenus la norme, les attaques se multiplient, ciblant à la fois les institutions financières et leurs clients. Les fraudeurs, toujours plus agiles, identifient rapidement les failles des systèmes classiques afin d'élaborer des schémas d'attaques complexes, difficilement détectables par des méthodes traditionnelles.

Par ailleurs, l'augmentation exponentielle des volumes de transactions réduit progressivement l'efficacité des outils historiques de surveillance. La capacité à repérer des comportements suspects devient plus limitée face à la diversité et à la rapidité des opérations. Il en résulte une surface d'exposition accrue, engendrant des conséquences financières et réputationnelles significatives pour les établissements concernés.

2.2.2 Contexte des anomalies dans les transactions bancaires en Tunisie

Le secteur bancaire tunisien est confronté à un défi croissant lié aux anomalies transactionnelles, principalement d'origine externe (réalisées par des clients malveillants, des cybercriminels ou des réseaux organisés), bien que des cas internes (impliquant des employés) puissent également survenir. Ces anomalies se manifestent par des comportements transactionnels inhabituels, des schémas suspects et des opérations non conformes aux profils clients établis. Elles peuvent entraîner des pertes financières significatives, exposer les établissements à des risques de non-conformité réglementaire et affecter la confiance des clients légitimes.

2.2.3 Types d'anomalies dans les transactions bancaires

Les anomalies transactionnelles se divisent en plusieurs catégories reflétant les différentes manières dont les systèmes de paiement et les comptes bancaires peuvent être exploités de façon suspecte. Elles correspondent à des comportements ou à des patterns qui s'écartent fortement des normes établies et peuvent indiquer des tentatives de fraude, de blanchiment ou de contournement des mécanismes de sécurité.

1. Anomalies externes (focus principal du projet) :

Les anomalies d'origine externe représentent la majorité des cas suspects et constituent le cœur de notre analyse.

A. **Transactions fragmentées suspectes** : multiples transactions de faible montant effectuées en succession rapide afin d'échapper aux seuils de surveillance automatique.

B. **Patterns de transactions inhabituels** :

- fréquence anormale de transactions.
- montants atypiques par rapport aux habitudes.
- horaires inhabituels (transactions nocturnes répétées).
- utilisation soudaine d'un nouveau canal de paiement.

C. **Vol d'identité et usurpation de compte** :

- changements brusques de localisation géographique.
- séquences d'opérations incohérentes avec l'historique.
- tentatives multiples d'authentification.

D. **Blanchiment d'argent potentiel** :

- virements multiples entre comptes.
- dépôts suivis de retraits quasi immédiats.
- utilisation de comptes de transit.

E. **Exploitation de failles systèmes** : tentatives répétées d'opérations refusées suivies d'ajustements progressifs.

F. **Arnaque du card skimming (faux DAB)** : Le skimming est une fraude nécessitant un travail préparatoire précis. Les escrocs se servent d'un équipement spécial introduit dans les automates ou à proximité, qui copie les données contenues sur la piste magnétique de la carte bancaire et enregistre le code personnel.[8]

G. Gonflement fictif des transactions pour l'obtention d'un emprunt :

Un client peut volontairement augmenter artificiellement le volume de ses transactions ou générer des opérations fictives afin de donner l'impression d'une activité financière plus importante. L'objectif est d'améliorer son profil financier auprès de la banque afin d'augmenter ses chances d'obtenir un crédit. Ce comportement peut se traduire par des flux financiers inhabituels ou un volume de transactions incohérent avec l'activité réelle du client.

Anomalies spécifiques par canal :

— **GAB (Guichets Automatiques Bancaires) :**

- retraits successifs dans des zones géographiquement éloignées en un court intervalle.
- montants de retrait inhabituels par rapport au profil du client.
- utilisation simultanée suspecte d'une même carte.

— **TPE (Terminaux de Paiement Électronique) :**

- transactions présentant des incohérences en termes de localisation ou de montant.
- utilisation de la carte dans des points de vente géographiquement éloignés dans un intervalle de temps très court.
- fréquence anormalement élevée de remboursements ou d'annulations au niveau d'un même point de vente.

— **Paiement mobile :**

- connexion depuis un nouvel appareil ou une nouvelle adresse IP.
- plusieurs comptes associés à un même appareil.
- anomalies comportementales (vitesse de frappe, gestes inhabituels).

— **E-commerce :**

- tentatives répétées de connexion infructueuses.
- connexions depuis de nouveaux appareils ou emplacements.
- schémas liés à la fraude amicale (contestations fréquentes, taux de retour anormal).[9]

2. Anomalies internes (cas secondaires) :

Bien que moins fréquentes, des anomalies d'origine interne peuvent également exister :

- A. manipulations de transactions par des employés.
- B. contournement des procédures de validation.
- C. accès abusifs aux données clients sans justification professionnelle.

Dans le cadre de ce projet, l'analyse se concentre principalement sur les anomalies d'origine **externe**, qui représentent le risque dominant et le cas d'usage prioritaire du dispositif de suspicion étudié.

2.2.4 Impact économique et social

Les anomalies et fraudes dans les transactions bancaires génèrent des impacts économiques et sociaux majeurs, affectant à la fois les institutions financières, les clients et l'écosystème numérique dans son ensemble. Au-delà des pertes monétaires directes, leurs effets s'étendent aux coûts opérationnels, à la confiance des usagers et aux exigences réglementaires. Ces répercussions créent des défis stratégiques pour les banques, qui doivent simultanément renforcer leurs mécanismes de contrôle, maintenir la qualité de service et préserver leur image.

Les conséquences se manifestent à plusieurs niveaux :

- **Impact économique pour les institutions** Les pertes financières ne se limitent pas aux montants détournés. Elles incluent également les coûts d'investigation, de remboursement, de correction des opérations, de renforcement des infrastructures de sécurité et de mise à niveau des systèmes de surveillance. À cela s'ajoutent les dépenses liées aux audits, aux procédures juridiques et à la mise en conformité.
- **Impact opérationnel** La gestion des transactions suspectes mobilise des ressources humaines et techniques importantes. Elle peut ralentir certains processus internes, augmenter la charge des équipes de contrôle et nécessiter la mise en place de procédures supplémentaires de validation et de vérification.
- **Confiance et comportement des clients** La répétition d'incidents liés à la fraude ou à des opérations suspectes peut réduire la confiance des clients envers les services bancaires numériques. Cela peut entraîner une baisse d'utilisation des services en ligne, une réticence envers les nouveaux moyens de paiement ou un changement d'établissement bancaire.
- **Impact social et numérique** À l'échelle sociétale, la montée des fraudes favorise un climat d'insécurité numérique et renforce la nécessité de sensibilisation des utilisateurs aux bonnes pratiques. Elle accentue également la fracture entre les utilisateurs confiants dans les services digitaux et ceux qui les évitent par crainte du risque.
- **Contraintes réglementaires et réputationnelles** Les établissements bancaires sont soumis à des obligations strictes de surveillance et de déclaration. Une mauvaise gestion des anomalies peut conduire à des sanctions, des amendes ou des restrictions réglementaires. L'impact réputationnel peut être durable et influencer la position concurrentielle de la banque sur le marché.[10]

2.2.5 Indicateurs de suspicion transactionnelle

La suspicion d'anomalies transactionnelles repose sur un ensemble d'indicateurs quantitatifs et comportementaux permettant d'identifier des écarts par rapport aux profils d'activité habituels. Ces indicateurs servent de signaux d'alerte préliminaires et alimentent les modèles analytiques.

Parmi les indicateurs fréquemment utilisés figurent la fréquence des transactions, la variation des montants, les ratios entre montants maximum et moyen, la dispersion des opérations, la diversité des canaux utilisés, ainsi que la répartition temporelle. L'analyse combinée de ces métriques permet de construire un score de risque ou un profil comportemental par compte.

2.2.6 Rôle stratégique de l'Intelligence Artificielle dans la suspicion d'anomalies transactionnelles

L'intelligence artificielle constitue un pilier central des approches modernes de surveillance et de suspicion d'anomalies dans les transactions bancaires. Elle permet d'analyser de grands volumes de données transactionnelles, d'identifier des schémas complexes et de mettre en évidence des comportements atypiques difficilement détectables par des règles statiques. Cette section présente les fondements de l'IA appliquée au contexte bancaire, les principales familles d'apprentissage automatique mobilisables, ainsi que les mécanismes analytiques d'aide à la décision qui en découlent.




FIGURE 2.1 – Composantes de l'IA [3]

Fondements de l'Intelligence Artificielle appliquée aux anomalies transactionnelles : L'intelligence artificielle (IA) est l'ensemble des systèmes informatiques capables d'effectuer des tâches typiquement associées à l'intelligence, telles que l'apprentissage, le raisonnement, la résolution de problèmes, la perception ou la prise de décision. L'intelligence artificielle est également le champ de recherche visant à développer de tels systèmes.

L'IA est un domaine de l'informatique qui s'appuie sur des fondements mathématiques (statistiques, algèbre linéaire, probabilités) et des concepts issus des sciences cognitives. Elle vise à résoudre des problèmes à forte complexité logique ou algorithmique.

Dans les systèmes de surveillance bancaire, ces approches permettent d'automatiser le filtrage initial des transactions, de réduire la dépendance aux règles fixes et d'orienter les analystes vers les cas les plus critiques.

Dans le contexte bancaire, l'IA est particulièrement pertinente pour :

- traiter de grands volumes de transactions en quasi temps réel ;

- identifier des patterns complexes invisibles à l'analyse manuelle ;
- s'adapter aux évolutions des comportements transactionnels ;
- réduire le taux de faux positifs des systèmes traditionnels.

Les composantes principales sont :

- **Apprentissage automatique (Machine Learning) :**
 - apprentissage à partir des données historiques ;
 - modélisation du comportement transactionnel normal ;
 - détection automatique des écarts significatifs ;
 - adaptation dynamique des seuils de suspicion.
- **Apprentissage profond (Deep Learning) :**
 - réseaux de neurones multicouches ;
 - analyse de données multidimensionnelles ;
 - détection de corrélations non linéaires ;
 - adapté aux séquences transactionnelles complexes ;
 - nécessite plus de données et de puissance de calcul.
- **Apprentissage par renforcement (Reinforcement Learning) :**
 - apprentissage par interaction avec un environnement ;
 - prise de décision basée sur un système de récompenses et de pénalités ;
 - amélioration progressive d'une stratégie (politique) optimale ;
 - maximisation des récompenses cumulées à long terme ;
 - adaptation dynamique par exploration et exploitation.

Approches d'apprentissage pour la suspicion d'anomalies :

Approche supervisée : L'approche supervisée est la plus directe lorsque des données historiques annotées sont disponibles. Le modèle apprend à distinguer les transactions normales des transactions suspectes à partir d'exemples passés étiquetés par des analystes ou des systèmes de conformité. Par exemple, dans un contexte bancaire, un modèle entraîné sur des milliers de virements internationaux frauduleux confirmés peut apprendre à reconnaître des schémas caractéristiques tels qu'un montant inhabituel, une destination à risque ou une fréquence anormale d'opérations.

Parmi ses avantages, cette approche offre une bonne précision lorsque les labels sont fiables, une interprétabilité possible des décisions, ainsi que la capacité à générer des scores de risque permettant de prioriser les alertes. Les modèles les plus performants dans ce cadre sont le **Random Forest** et le **Gradient Boosting** (XGBoost, LightGBM). Toutefois, un défi majeur reste le fort déséquilibre entre classes — les transactions frauduleuses étant minoritaires — ce qui est traité par des techniques telles que le sur-échantillonnage (SMOTE), la pondération des classes ou le sous-échantillonnage contrôlé.




FIGURE 2.2 – Approche supervisée [4]

Approche non supervisée : Lorsqu’aucune donnée étiquetée n’est disponible, ou que l’on cherche à détecter des fraudes encore inconnues, l’approche non supervisée devient indispensable. Elle repose sur l’hypothèse que les comportements frauduleux sont rares et structurellement différents des comportements normaux. Le modèle apprend ainsi la structure des données sans aucune supervision humaine préalable.

À titre d’exemple, un client qui effectue soudainement dix retraits d’espèces en une heure dans des villes différentes présentera un profil très éloigné de son comportement habituel, ce qu’un modèle non supervisé peut détecter comme une anomalie significative. Les méthodes les plus utilisées sont l’**Isolation Forest**, qui isole rapidement les points atypiques en partitionnant aléatoirement l’espace de données, le **Local Outlier Factor**, qui évalue le degré d’isolement d’une observation par rapport à son voisinage local, et le **One-Class SVM**, qui modélise une frontière englobant le comportement normal et signale tout point en dehors comme suspect.




FIGURE 2.3 – Approche non supervisée[5]

Approche semi-supervisée : L’approche semi-supervisée représente un compromis pragmatique entre les deux précédentes, particulièrement bien adaptée à la réalité opérationnelle des institutions bancaires. En pratique, il est rare de dis-

poser d'un grand volume de transactions frauduleuses confirmées, mais il est en revanche possible d'obtenir un petit ensemble de cas validés par des analystes, combiné à une large masse de données non étiquetées.

2.2.7 Exploitation du machine learning dans le cadre de la suspicion et de la prévention de la fraude

Du fait de sa capacité à analyser de grandes quantités de données, à identifier des mécanismes récurrents et à s'adapter aux nouvelles informations, le machine learning est de plus en plus utilisé dans la prévention et la détection de la fraude [11]. Les principales applications sont les suivantes :

- **Détection des anomalies** : Les algorithmes de machine learning identifient, dans les données transactionnelles, les comportements inhabituels et les écarts par rapport aux habitudes traditionnelles. En s'entraînant à partir de données historiques, ils apprennent à distinguer les transactions légitimes des activités suspectes pouvant indiquer une fraude.
- **Cotation des risques** : Les modèles attribuent des scores de risque aux transactions ou aux comptes utilisateurs en se basant sur plusieurs facteurs tels que le montant, la fréquence des opérations, la localisation ou encore les comportements antérieurs. Un score élevé indique une probabilité plus importante de fraude et permet de prioriser les investigations.
- **Analyse des réseaux** : Les fraudeurs agissent souvent en réseau. Les techniques d'analyse de graphes permettent d'identifier les relations entre différentes entités (utilisateurs, comptes, appareils) et de détecter des connexions inhabituelles ou des clusters suspects.
- **Analyse de texte** : Les algorithmes peuvent exploiter des données textuelles non structurées (courriels, messages sur les réseaux sociaux, réclamations clients) afin d'identifier des mots-clés ou des schémas linguistiques révélateurs d'une tentative de fraude.
- **Vérification d'identité** : Les modèles de machine learning analysent et valident les informations fournies par les utilisateurs, telles que les documents d'identité ou les données biométriques (reconnaissance faciale), afin de prévenir l'usurpation d'identité.
- **Apprentissage adaptatif** : L'un des principaux avantages du machine learning réside dans sa capacité d'adaptation. Les modèles peuvent être réentraînés à partir de nouvelles données afin de s'ajuster aux évolutions des techniques frauduleuses et d'améliorer continuellement leurs performances.

L'utilisation du machine learning dans la prévention de la fraude peut être un moyen puissant pour les organisations de renforcer leurs capacités de détection, de réduire le risque de faux positifs et d'améliorer la sécurité et l'expérience client dans leur ensemble.

2.2.8 Notion d'anomalie vs fraude

Dans le contexte bancaire, il est essentiel de distinguer la notion d'anomalie de celle de fraude. Une anomalie correspond à un comportement transactionnel in-

habituel ou atypique par rapport aux habitudes normales d'un compte ou d'un ensemble de clients, sans pour autant constituer une fraude avérée. À l'inverse, une fraude désigne une activité illégale confirmée, établie après une analyse approfondie et une investigation humaine. Dans ce projet, l'objectif n'est pas de détecter directement des fraudes, mais plutôt de soupçonner des comportements anormaux susceptibles de révéler un risque potentiel. Les modèles de détection utilisés génèrent ainsi des alertes de suspicion, basées sur des indicateurs comportementaux tels que la fréquence des transactions, la variation des montants, l'activité nocturne ou les incohérences géographiques. Ces alertes constituent une étape préliminaire du processus de contrôle, permettant aux analystes bancaires de concentrer leurs efforts sur les cas les plus à risque, tout en évitant d'assimiler systématiquement une anomalie à une fraude confirmée.

2.3 Détection des schémas suspects

La détection des schémas suspects consiste à identifier des comportements transactionnels inhabituels pouvant indiquer une activité frauduleuse ou anormale. Dans ce projet, cette étape repose sur l'analyse des comptes bancaires à travers plusieurs variables telles que le nombre de transactions, les montants, la fréquence, la dispersion des opérations et la diversité des lieux. L'objectif est de repérer des comportements qui s'écartent du profil habituel d'un compte.

2.4 Sécurité et conformité réglementaire

La sécurité des transactions et la conformité aux normes réglementaires (comme ISO/IEC 27001, ISO/IEC 27002, GDPR / RGPD, etc.) sont des piliers essentiels pour les banques tunisiennes, particulièrement exposées aux fraudes internes et externes. La mise en place d'outils analytiques et de tableaux de bord permet de renforcer ces aspects tout en soutenant la durabilité économique du secteur.

2.4.1 Renforcement de la sécurité

Le renforcement de la sécurité vise à protéger les transactions bancaires contre les menaces posées par les fraudes, un enjeu central pour maintenir la stabilité des institutions financières. Cette démarche repose sur l'utilisation de solutions innovantes permettant de surveiller les activités suspectes et de renforcer les défenses contre les attaques internes ou externes. Elle contribue à réduire les pertes économiques tout en améliorant la confiance des acteurs concernés dans le système bancaire. Ainsi, elle établit une base solide pour une bonne gestion des risques liés aux fraudes.

-Les solutions proposées dans ce projet permettent :

- la surveillance des opérations afin de détecter les anomalies ou comportements suspects ;
- l'identification des fraudes internes (employés manipulant des transactions) et externes (clients ou cybercriminels), réduisant ainsi les pertes financières ;
- l'amélioration des contrôles internes, en fournissant aux équipes de sécurité des informations exploitables pour agir rapidement.[12]

2.4.2 Impact économique et durable

L'impact économique et durable reflète la manière dont la sécurité et la conformité renforcent non seulement les performances financières à court terme, mais également la durabilité à long terme des banques. Cette influence se manifeste à travers des mesures qui construisent une relation de confiance avec les clients et les partenaires, tout en adaptant les systèmes aux défis futurs. Elle joue un rôle essentiel dans la création d'un secteur bancaire résilient, capable de résister à l'évolution des fraudes tout en optimisant ses ressources. Ainsi, elle soutient une croissance durable et alignée avec les ambitions stratégiques des institutions financières.

-La sécurité et la conformité ne protègent pas seulement contre les pertes immédiates :

- elles contribuent à la durabilité économique du secteur bancaire en instaurant la confiance auprès des clients et des partenaires financiers ;
- elles permettent d'optimiser les processus et de rendre les systèmes plus résilients face aux nouvelles menaces et aux fraudes évolutives..[12]

2.5 Compréhension métier

La phase de compréhension métier constitue le point de départ de la méthodologie CRISP-DM. Elle vise à analyser le contexte professionnel du projet, à identifier les enjeux associés aux anomalies transactionnelles et à définir clairement les objectifs à atteindre en adéquation avec les besoins opérationnels de la banque.

Cette étape correspond à la raison d'être du projet. Il s'agit d'identifier les problèmes et définir les objectifs qui permettront d'évaluer in fine le projet et identifier les ressources disponibles ; qu'il s'agisse du personnel ou du matériel.[13]

2.5.1 Objectifs du projet

Les objectifs définis dans ce projet, réalisé au sein de la BH Bank, s'inscrivent dans une logique de renforcement du dispositif de surveillance des transactions à travers l'exploitation des techniques d'analyse de données et d'apprentissage automatique.

Ils se déclinent comme suit :

- **Mettre en place un système de détection des anomalies transactionnelles** : concevoir un modèle analytique capable d'identifier des comportements inhabituels au niveau des comptes bancaires, sans conclure directement à une fraude avérée.
- **Améliorer l'anticipation des risques financiers** : développer des indicateurs permettant de détecter précocement des activités atypiques susceptibles de générer des pertes ou d'exposer la banque à des risques opérationnels.
- **Optimiser le processus d'analyse interne** : proposer un outil d'aide à la décision facilitant la priorisation des investigations, tout en réduisant les faux positifs et en améliorant la pertinence des alertes.
- **Adapter les méthodes de détection au contexte bancaire tunisien** : concevoir une approche tenant compte des contraintes locales, notamment

la rareté des données étiquetées et la nécessité d'intégrer des méthodes non supervisées.

2.5.2 Étapes principales du projet

Conformément à la méthodologie CRISP-DM (*Cross Industry Standard Process for Data Mining*), la réalisation du projet s'articule autour des étapes suivantes :

- **Compréhension du métier (Business Understanding)** : analyse du contexte bancaire, identification des enjeux liés aux risques transactionnels et définition des objectifs du projet en cohérence avec les besoins métier.
- **Compréhension des données (Data Understanding)** : exploration des données disponibles afin d'en analyser la structure, la qualité et les relations entre variables, tout en identifiant les indicateurs pertinents.
- **Préparation des données (Data Preparation)** : nettoyage, transformation et structuration des données pour les rendre exploitables, incluant la gestion des valeurs manquantes, la normalisation et la création de variables comportementales.
- **Modélisation (Modeling)** : développement et optimisation de modèles d'apprentissage supervisé, non supervisé et de *deep learning* afin de détecter les comportements atypiques et générer des scores de suspicion.
- **Évaluation (Evaluation)** : évaluation des modèles à l'aide de métriques adaptées (AUC-ROC, Precision, Recall, F1-score, ainsi que des indices de clustering), afin de vérifier leur performance et leur adéquation aux objectifs métier.
- **Déploiement (Deployment)** : intégration des résultats dans un environnement opérationnel, à travers des outils interactifs facilitant la visualisation des indicateurs et la prise de décision.

2.5.3 Outils utilisés

Cette section présente les principaux outils techniques mobilisés dans le cadre du projet, couvrant les différentes phases allant de l'analyse des données jusqu'au déploiement de la solution.

- **Jupyter Notebook** : Un environnement interactif utilisé pour l'exploration des données, le prototypage des modèles d'apprentissage automatique et la documentation des expérimentations, en combinant code, visualisations
- **Visual Studio Code (VS Code)** : Un environnement de développement intégré utilisé pour implémenter l'ensemble de la solution. Il a permis de développer l'application web, d'intégrer les modèles et de gérer les différents modules du projet. À travers cet environnement, plusieurs technologies ont été mobilisées, notamment :
 - **Flask** pour le développement du backend et des API de prédiction .
 - **LangChain** et **ChromaDB** pour la mise en place du chatbot basé sur une architecture RAG .
 - les technologies web (**HTML**, **CSS**, **JavaScript**, **Jinja2**) pour la conception de l'interface utilisateur .

et analyses.

- **Power BI** : Un outil de Business Intelligence permettant de concevoir des tableaux de bord interactifs pour la visualisation des données et des indicateurs clés liés aux comportements transactionnels.

2.6 Conclusion

Ce chapitre a permis d'établir les fondements théoriques et métier nécessaires à la compréhension du projet. Nous avons exploré les différents types d'anomalies transactionnelles, les approches d'intelligence artificielle applicables à leur détection, ainsi que la distinction essentielle entre anomalie et fraude confirmée. La compréhension métier réalisée dans le cadre de la méthodologie CRISP-DM a permis de définir clairement les objectifs du projet et d'orienter les choix analytiques vers une approche de détection de suspicions d'anomalies, adaptée aux contraintes du contexte bancaire tunisien. Le chapitre suivant sera consacré à la compréhension et à la préparation des données transactionnelles de la BH Bank, constituant ainsi la base concrète de la modélisation.

Chapitre 3 : Compréhension et préparation des données

3.1 Introduction

Ce chapitre s'inscrit dans le cadre de la méthodologie CRISP-DM et couvre les phases de compréhension et de préparation des données. Ces étapes jouent un rôle fondamental dans la réussite du projet, car elles permettent de transformer des données transactionnelles brutes en un ensemble structuré et exploitable pour la modélisation.

Dans le contexte de la détection des anomalies bancaires, la qualité et la pertinence des données sont essentielles pour identifier des comportements atypiques. Une analyse approfondie des données permet de mieux comprendre les caractéristiques des transactions, de détecter d'éventuelles incohérences et d'orienter les choix de transformation.

Ce chapitre présente ainsi les différentes étapes suivies pour analyser, nettoyer et préparer les données, tout en mettant en évidence leur impact sur la performance des modèles de détection.

1- Objectif de la phase de compréhension des données :

- Comprendre la structure des données transactionnelles et la signification des variables disponibles.
- Analyser la qualité des données en identifiant les valeurs manquantes, les incohérences et les données aberrantes.
- Explorer les distributions des variables afin de détecter des comportements typiques et atypiques.
- Identifier les relations entre les variables et les indicateurs pertinents pour la détection des anomalies.
- Mettre en évidence les premières pistes de comportements suspects à travers l'analyse exploratoire.

2- Objectif de la phase de préparation des données :

- Nettoyer les données en traitant les valeurs manquantes, les doublons et les incohérences.
- Transformer les données pour les rendre exploitables par les algorithmes de machine learning (normalisation, encodage, agrégation).
- Construire des variables comportementales (feature engineering) permettant de mieux représenter les profils des comptes.
- Réduire la dimensionnalité des données afin d'améliorer la performance des modèles .
- Préparer un jeu de données final structuré, cohérent et adapté aux modèles de détection d'anomalies.

3.2 Compréhension des données

3.2.1 Description générale

Les données utilisées dans ce projet proviennent de la banque BH Bank (Tunisie) et couvrent la période allant de 2024 à 2025.

Elles étaient initialement fournies sous format Excel, ce qui a nécessité une étape de traitement pour les rendre exploitables dans notre pipeline d'analyse.

3.2.2 Structure des données brutes

Le projet repose principalement sur le fichier transactionnel fourni par BH Bank (Tunisie) :

- **Fichier `operations_comptes.xls`** : contient les transactions détaillées associées aux comptes bancaires.
- **Fichier `clients.xls`** : contient les informations relatives aux clients.

Dans le cadre de ce projet, l'analyse a été centrée sur les comportements transactionnels des comptes bancaires et non sur le profil individuel des clients. Par conséquent, le fichier `clients.xls` n'a pas été exploité dans la phase de modélisation.

À partir du fichier `operations_comptes.xls`, une étape de *feature engineering* a été réalisée afin de générer un nouveau fichier `features_comptes.xlsx`, contenant 25 caractéristiques comportementales décrivant l'activité de chaque compte bancaire.

La relation entre les différents fichiers est assurée par la clé **compte**, permettant d'identifier de manière unique chaque compte dans les différentes sources de données.

3.2.3 Scénarios de fraude identifiés

Dans le cadre de ce projet, plusieurs scénarios de fraude ont été identifiés à partir de l'analyse des comportements transactionnels. Ces scénarios s'inspirent de situations réelles observées dans le secteur bancaire, notamment le clonage de cartes, le vol d'identité et les activités de blanchiment d'argent.

Les principaux cas potentiellement frauduleux sont les suivants :

- **Transactions de faible montant suivies de retraits importants** : Ce comportement peut correspondre à une phase de test de carte bancaire (clonée ou compromise), où de petites transactions sont effectuées pour vérifier la validité avant de procéder à des retraits significatifs.
- **Succession rapide de montants croissants** : Une augmentation progressive et rapide des montants peut indiquer une tentative d'exploitation d'un compte après une compromission, où le fraudeur augmente progressivement les montants pour éviter une détection immédiate.
- **Transactions répétées de faibles montants** : Ce schéma, souvent appelé *smurfing*, peut être associé à des tentatives de contournement des seuils de détection ou à des opérations de blanchiment d'argent fractionnées.

- **Débets et crédits de montants similaires** : Ce type d'opérations peut révéler des mouvements artificiels de fonds visant à simuler une activité économique plus importante qu'en réalité. L'objectif peut être de gonfler artificiellement le chiffre d'affaires du compte afin d'améliorer son profil financier et d'obtenir, par exemple, un crédit bancaire plus élevé.
- **Transactions dans des localisations éloignées sur un temps court** : Des opérations effectuées dans des zones géographiques différentes en un intervalle de temps réduit sont difficilement explicables par un comportement normal et peuvent indiquer un clonage de carte ou une utilisation frauduleuse à distance.
- **Changement brusque de comportement transactionnel** : Un passage soudain d'une activité habituelle (par exemple diurne) à des transactions nocturnes inhabituelles peut refléter une prise de contrôle du compte par un tiers ou une utilisation anormale.
- **Multiples paiements TPE de faible montant sur une courte période** : La réalisation répétée de paiements inférieurs à 100 DT sur des terminaux de paiement électronique (*TPE*) dans un intervalle de temps réduit peut représenter un comportement suspect. En effet, ce type de transaction ne nécessite généralement pas la saisie du code PIN, ce qui peut faciliter l'utilisation frauduleuse d'une carte bancaire clonée ou volée avant son blocage par la banque.

Ces scénarios reflètent des comportements transactionnels atypiques et constituent une base pertinente pour l'analyse et la détection des anomalies.

3.2.4 Structure et description des variables du dataset

Dans cette section, nous présentons la structure détaillée des deux fichiers principaux utilisés dans notre étude : le fichier des opérations bancaires et le fichier des caractéristiques agrégées par compte.

Fichier des opérations bancaires (`operations_comptes.xls`) : Ce fichier constitue la source primaire de données transactionnelles de notre étude. Il contient l'historique détaillé de 11,309 transactions bancaires effectuées sur la période d'observation. Chaque ligne représente une transaction individuelle avec ses métadonnées associées (montant, date, lieu, type d'opération, etc.).

Ce fichier permet l'analyse granulaire des comportements transactionnels et sert de base pour la construction des caractéristiques comportementales agrégées.

Il contient également la variable cible `anomalie`, qui identifie les transactions suspectes. Les anomalies sont générées par des règles métier validées par l'encadrant professionnel, garantissant la fiabilité et la pertinence des labels pour l'apprentissage automatique.

TABLE 3.1 – Description des variables du fichier `opérations_comptes.xls`

Variable	Type de Données	Description
<code>numero_piece_identite</code>	float64	Numéro de pièce d'identité du client .
<code>compte</code>	object	Identifiant unique du compte bancaire .
<code>montant</code>	float64	Montant de la transaction en dinars tunisiens (DT).
<code>sens_operation</code>	object	Sens de l'opération : <i>Crédit</i> ou <i>Débit</i> .
<code>ID_transaction</code>	object	Identifiant unique de la transaction permettant la traçabilité et l'audit
<code>motif_operation</code>	object	Motif ou libellé de la transaction (ex. : virement, retrait DAB, paiement TPE, etc.)
<code>agence</code>	float64	Code numérique de l'agence bancaire où la transaction a été effectuée
<code>lieu</code>	object	Localisation géographique de la transaction .
<code>date_operation</code>	object	Date et heure de la transaction .
<code>anomalie</code>	float64	Variable cible binaire : 0 = transaction normale, 1 = transaction suspecte. Les anomalies sont générées par des règles métier validées par l'encadrant professionnel

Statistiques du fichier `opérations_comptes.xls` :

- **Nombre total de transactions** : 11,309
- **Transactions valides (non-nulles)** : 11,005
- **Transactions manquantes** : 304 (2.69%)
- **Nombre de comptes distincts** : 2,839
- **Période couverte** : Janvier 2024 – Décembre 2025
- **Doublons détectés** : 303 lignes (2.68%)

Distribution des variables catégorielles :

- **Sens opération** : 2 valeurs uniques
 - Débit (D) : 9,940 transactions (90.3%)
 - Crédit (C) : 1,065 transactions (9.7%)
- **Lieux géographiques** : 25 villes/régions distinctes
- **Motifs d'opération** : 593 motifs uniques
- **ID_transaction** : 8,941 identifiants uniques

Valeurs aberrantes (outliers) détectées :

- **Montant** : 892 outliers (8.1%)
 - Intervalle normal (IQR) : [-480 DT, 928 DT]
 - Intervalle observé : [5 DT, 200,000 DT]
 - *Interprétation* : Présence de transactions extrêmes nécessitant validation

Fichier des caractéristiques agrégées (features_comptes.xlsx) : Ce fichier résulte de l'ingénierie des caractéristiques (*feature engineering*) appliquée au fichier des opérations. Il contient 25 caractéristiques comportementales calculées par compte, regroupées en 5 catégories :

- (1) caractéristiques de volume et montant,
- (2) caractéristiques temporelles,
- (3) caractéristiques géographiques,
- (4) patterns de fraude,
- (5) caractéristiques de mobilité.

Ces features sont conçues pour capturer des comportements suspects tels que les délais anormalement courts entre transactions, les montants variables, et la mobilité géographique inhabituelle. Ce fichier sert d'entrée directe aux algorithmes de machine learning.

TABLE 3.2 – Description des variables du fichier `features_comptes.xlsx`

Variable	Type	Description
Identifiant et volume transactionnel		
<code>compte</code>	object	Identifiant unique du compte bancaire
<code>nb_transactions</code>	int64	Nombre total de transactions effectuées par le compte
<code>nb_transactions_mois</code>	float64	Fréquence mensuelle moyenne des transactions
<code>tx_par_jour</code>	float64	Nombre de transactions par jour
Caractéristiques de montants		
<code>total_montant</code>	float64	Somme totale des montants transactionnés (en DT)
<code>montant_moyen</code>	float64	Montant moyen par transaction
<code>montant_median</code>	float64	Montant médian
<code>montant_std</code>	float64	Écart-type des montants
<code>montant_min</code>	float64	Montant minimum transactionné
<code>montant_max</code>	float64	Montant maximum transactionné
<code>ratio_max_moyen</code>	float64	Ratio $\frac{\text{montant_max}}{\text{montant_moyen}}$
<code>ratio_montant_max_min</code>	float64	Ratio $\frac{\text{montant_max}}{\text{montant_min}}$
Caractéristiques temporelles		
<code>duree_activite_jours</code>	int64	Nombre de jours entre première et dernière transaction
<code>temps_moyen_entre_tx_min</code>	float64	Délai moyen (en minutes) entre deux transactions consécutives
<code>temps_median_entre_tx_min</code>	float64	Délai médian entre transactions
<code>temps_min_entre_tx_min</code>	float64	Délai minimum observé. Délais courts = indicateur suspect
<code>temps_std_entre_tx_min</code>	float64	Écart-type des délais entre transactions
<code>pct_nocturne</code>	float64	Pourcentage de transactions effectuées entre 22h et 6h
<code>pct_weekend</code>	float64	Pourcentage de transactions effectuées le week-end
Caractéristiques géographiques		
<code>nb_lieux_différents</code>	int64	Nombre de lieux géographiques distincts
<code>lieu_principal</code>	object	Lieu le plus fréquent des transactions
<code>pct_lieu_principal</code>	float64	Pourcentage de transactions au lieu principal
<code>changements_lieu_frequent</code>	float64	Fréquence de changement de lieu entre transactions
<code>velocite_maximale_km_h</code>	float64	Vitesse maximale calculée entre deux transactions
Patterns de fraude spécifiques		
<code>montants_croissants</code>	int64	Nombre de séquences de montants croissants consécutifs
<code>nb_tpe_moins_100</code>	int64	Nombre de transactions TPE inférieures à 100 DT
<code>ratio_tpe_moins_100</code>	float64	Proportion de petites transactions TPE sur le total des transactions

Statistiques du fichier `features_comptes.xlsx` :

- **Nombre de comptes** : 2,839
- **Nombre de features** : 25 caractéristiques comportementales + 1 identifiant (`compte`) + 1 variable géographique (`lieu_principal`)
- **Features numériques** : 25 (Int64 et Float64)
- **Features catégorielles** : 2 (`compte`, `lieu_principal`)
- **Valeurs manquantes** : 0 (aucune après prétraitement)
- **Doublons** : 0
- **Cardinalité moyenne** : 1,102 valeurs uniques par feature numérique

Observations statistiques importantes :

- **Volume transactionnel** :
 - Moyenne : 4 transactions/compte, médiane : 3 transactions (distribution asymétrique)
 - Maximum : 37 transactions (compte le plus actif)
- **Montants** :
 - Écart-type très élevé (5,084 DT) par rapport à la moyenne (713 DT)
 - Présence de valeurs extrêmes : montant max = 200,000 DT
 - Distribution fortement asymétrique (médiane 107 DT vs moyenne 713 DT)
- **Temporalité** :
 - Temps minimum entre transactions : moyenne 2,884 min (2 jours), médiane 156 min (2.6h)
 - Valeurs extrêmes : minimum 0.5 min (30 secondes), maximum 237,600 min (165 jours)
- **Comportements nocturnes et week-end** :
 - 13.9% transactions nocturnes en moyenne
 - 28.6% transactions week-end en moyenne
- **Mobilité géographique** :
 - Moyenne : 1.3 lieux distincts par compte
 - 70% des comptes opèrent depuis un seul lieu (médiane = 1)
 - Maximum : 7 lieux (multi-localisation suspecte)
- **Vitesse maximale calculée** :
 - Maximum : 24,000 km/h (détection claire d'impossibilité physique)
 - *Interprétation* : Indicateur de transactions simultanées multi-localisées (fraude type clone de carte)

3.2.5 Analyse exploratoire des données (EDA)

L'analyse exploratoire des données comprend l'utilisation de graphiques et de visuels pour explorer et analyser un jeu de données. L'objectif est d'explorer, de rechercher et d'apprendre, plutôt que de confirmer les hypothèses statistiques[14].

Analyse de la matrice de corrélation : L'analyse de la matrice de corrélation révèle plusieurs structures importantes dans les données :




FIGURE 3.1 – Matrice de corrélation des variables

Groupes de variables fortement corrélées : L'examen de la matrice met en évidence l'existence de blocs de corrélation élevée, notamment :

- **Variables de montants :** Les caractéristiques `montant_moyen`, `montant_median` et `montant_max` présentent des corrélations supérieures à 0.9, indiquant une forte redondance d'information. Ces trois variables mesurent essentiellement la même dimension comportementale (niveau des montants transactionnés).
- **Variables temporelles :** De même, `temps_moyen_entre_tx_min`, `temps_median_entre_tx_min` et `temps_min_entre_tx_min` affichent des corrélations comprises entre 0.6 et 0.9, reflétant la régularité temporelle des transactions.
- **Variables de fréquence :** Les corrélations entre `nb_transactions`, `nb_transactions_mois` et `tx_par_jour` (corrélations > 0.8) confirment qu'elles mesurent le même phénomène de volume d'activité sous différentes normalisations.

Corrélations négatives significatives : Certaines paires de variables présentent des corrélations négatives cohérentes avec l’expertise métier :

- La corrélation négative entre `pct_lieu_principal` et `changements_lieu_frequents` ($r \approx -0.7$) reflète la relation inverse attendue : les comptes opérant majoritairement depuis un seul lieu changent moins fréquemment de localisation.
- Une corrélation négative modérée est observée entre `duree_activite_jours` et `tx_par_jour` ($r \approx -0.5$), indiquant que les comptes avec une longue période d’activité tendent à avoir une fréquence journalière plus faible (activité diluée dans le temps).

Variables faiblement corrélées (information complémentaire) : Plusieurs variables présentent de faibles corrélations avec l’ensemble des autres features ($|r| < 0.3$), ce qui suggère qu’elles apportent une information complémentaire pertinente pour la détection d’anomalies :

- `pct_nocturne` : Corrélations faibles avec les variables de montants et de fréquence ($|r| < 0.2$), indiquant que les transactions nocturnes constituent un pattern indépendant, potentiellement discriminant pour la fraude.
- `pct_weekend` : Similairement, les transactions effectuées durant le week-end montrent une faible corrélation avec les autres dimensions comportementales ($|r| < 0.25$).
- `velocite_maximale_km_h` : Cette variable présente des corrélations quasi-nulles avec l’ensemble des autres features ($|r| < 0.15$), confirmant qu’elle capture un phénomène distinct (impossibilité physique de déplacement, indicateur de clonage de carte).
- `montants_croissants_consecutifs` et `ratio_tpe_moins_100` : Ces features spécifiques de détection de fraude affichent également de faibles corrélations ($|r| < 0.2$), justifiant leur inclusion dans le modèle malgré leur faible variance.

Implications pour la modélisation : Cette analyse révèle une structure de données composée de :

1. **Variables redondantes** : Nécessitant une réduction de dimensionnalité ou une sélection manuelle pour éviter la multicollinéarité .
2. **Variables indépendantes** : Apportant une information complémentaire essentielle pour capturer la diversité des patterns de fraude (temporalité, géolocalisation, impossibilité physique).

Deux stratégies de sélection de features ont donc été adoptées :

- **Pour les modèles supervisés** : Sélection par Information Mutuelle avec test de plusieurs seuils (, permettant de retenir les features les plus discriminantes tout en éliminant les redondances .
- **Pour les modèles non-supervisés** : Application de PCA (2 composantes) pour réduire la dimensionnalité tout en préservant la variance expliquée maximale, combinée à un Variance Threshold pour éliminer les variables constantes.

Globalement, cette analyse justifie pleinement l'utilisation de techniques de réduction de dimensionnalité et de sélection de variables dans la phase de préparation des données, tout en identifiant les features clés à préserver pour leur apport informatif unique.

Analyse de la distribution des variables explicatives : Afin de mieux comprendre la structure des données, une analyse univariée a été réalisée à travers la visualisation des distributions des principales variables. Ces histogrammes permettent d'identifier la présence d'asymétrie, de valeurs extrêmes ainsi que la dispersion des données.




FIGURE 3.2 – Analyse univariée des variables

Comme l'illustre la figure 3.2, l'analyse des distributions met en évidence une forte asymétrie pour plusieurs variables comportementales, notamment celles liées aux montants, aux fréquences transactionnelles et aux ratios d'activité. Cette caractéristique reflète l'hétérogénéité des comportements observés entre les comptes bancaires, où une majorité de comptes présentent une activité modérée tandis qu'un nombre réduit affiche des comportements beaucoup plus extrêmes.

Les variables telles que le pourcentage de transactions nocturnes, le nombre de lieux différents ou encore les changements fréquents de localisation montrent une concentration importante autour de faibles valeurs. Cela indique que la plupart des comptes suivent des habitudes transactionnelles relativement stables, alors qu'une minorité présente des comportements atypiques pouvant correspondre à des situations anormales ou suspectes.




FIGURE 3.3 – Comportement anormal d'un compte

Changement de comportement transactionnel : L'exemple présenté dans figure 3.3 illustre un cas parmi d'autres de changement significatif de comportement transactionnel observé dans les données. Initialement, les transactions du compte sont exclusivement réalisées durant la journée, comme l'indique un pourcentage de transactions nocturnes nul. Cependant, à partir d'une certaine période (matérialisée par la ligne de séparation), une transition nette est observée vers des transactions majoritairement nocturnes, avec un pourcentage atteignant plus de 80%.

Ce basculement soudain d'un comportement diurne vers un comportement nocturne constitue un indicateur fort d'anomalie, dans la mesure où il traduit une rupture avec les habitudes historiques du compte. Ce type de variation comportementale est souvent associé à des scénarios de fraude tels que le vol d'identité ou le clonage de carte bancaire, où l'utilisateur malveillant adopte des schémas d'utilisation différents du titulaire légitime.

3.3 Préparation des données

Une fois que les données ont été évaluées, il faut à présent sélectionner les variables et les échantillons pertinents pour l'analyse, en fonction des objectifs qui ont été fixés.

Les données sont ensuite nettoyées et, si nécessaire, transformées. Cela peut inclure la gestion des valeurs manquantes, l'échantillonnage des données et la création de variables dérivées. Si plusieurs sources de données sont utilisées, elles sont intégrées pour créer un ensemble de données cohérent[15].

3.3.1 Chargement des données

Le chargement des données constitue la première étape pratique du processus CRISP-DM. Elle vise à rendre les informations disponibles sous un format exploitable, afin de faciliter leur exploration et leur préparation pour les étapes suivantes.

Cette étape comprise :

- Importation des bibliothèques nécessaires, notamment `pandas` et `numpy`.
- Chargement des fichiers de données au format Excel (`opérations_comptes.xls` et `features_comptes.xlsx`) à l'aide de la fonction `read_excel()`.
- Vérification du bon chargement des données en affichant les dimensions des jeux de données (nombre de lignes et de colonnes).
- Inspection des premières lignes du dataset à l'aide de la fonction `head()` afin de valider la structure des données.
- Vérification des types de variables (`dtypes`) pour identifier les colonnes numériques et catégorielles.
- Identification des variables clés, notamment la variable `compte` utilisée pour la jointure entre les fichiers.

Informations générales du dataset : L'analyse des informations générales du fichier `features_comptes` montre qu'il contient un total de 2 839 observations correspondant à des comptes bancaires, décrits par 27 variables. Ces variables ont été construites à partir du fichier des transactions `opérations_comptes.xls` à travers un processus d'ingénierie des caractéristiques, permettant de transformer des données transactionnelles brutes en indicateurs comportementaux agrégés par compte, comme illustré dans la figure 3.4.

Parmi ces variables, la majorité est de type numérique, avec 20 variables de type `float64` et 5 variables de type `int64`, ce qui reflète la nature quantitative des caractéristiques générées. Deux variables sont de type catégoriel (`object`), notamment l'identifiant du compte (`compte`) et le lieu principal (`lieu_principal`).

```

Data columns (total 27 columns):
#   Column                                     Non-Null Count  Dtype
---  -
0   compte                                     2839 non-null   object
1   nb_transactions                           2839 non-null   int64
2   total_montant                             2839 non-null   float64
3   montant_moyen                             2839 non-null   float64
4   montant_median                           2839 non-null   float64
5   montant_std                               2839 non-null   float64
6   montant_min                               2839 non-null   float64
7   montant_max                               2839 non-null   float64
8   duree_activite_jours                     2839 non-null   int64
9   ratio_max_moyen                          2839 non-null   float64
10  nb_transactions_mois                      2839 non-null   float64
11  pct_nocturne                              2839 non-null   float64
12  pct_weekend                              2839 non-null   float64
13  nb_lieux_differeents                     2839 non-null   int64
14  lieu_principal                           2839 non-null   object
15  pct_lieu_principal                       2839 non-null   float64
16  changements_lieu_frequents               2839 non-null   float64
17  temps_moyen_entre_tx_min                 2839 non-null   float64
18  temps_median_entre_tx_min                 2839 non-null   float64
19  temps_min_entre_tx_min                   2839 non-null   float64
20  temps_std_entre_tx_min                   2839 non-null   float64
21  montants_croissants_consecutifs         2839 non-null   int64
22  ratio_montant_max_min                    2839 non-null   float64
23  velocite_maximale_km_h                   2839 non-null   float64
24  nb_tpe_moins_100                         2839 non-null   int64
25  ratio_tpe_moins_100                      2839 non-null   float64
26  tx_par_jour                              2839 non-null   float64
dtypes: float64(20), int64(5), object(2)

```

FIGURE 3.4 – Informations générales

3.3.2 Prétraitement des données

Dans cette étape, un ensemble de traitements a été appliqué afin de garantir la qualité des données et leur adéquation aux algorithmes de machine learning. Le prétraitement des données constitue une phase essentielle permettant d'améliorer la performance des modèles et d'assurer la fiabilité des résultats obtenus.

— Nettoyage des données

Cette étape a été réalisée sur le fichier transactionnel brut `opérations_comptes`. Elle consiste principalement en la suppression des doublons, qui peuvent introduire un biais dans l'analyse, ainsi que le traitement des valeurs manquantes. Les valeurs manquantes ont été remplacées par des statistiques appropriées, notamment la médiane pour les variables numériques, afin de préserver la distribution des données.

La figure 3.5 illustre l'état des données avant et après nettoyage, mettant en évidence l'amélioration de leur qualité ainsi que l'absence de valeurs man-

quantas après traitement.

```
-----  
Doublons avant: 303  
Doublons supprimés  
Doublons après: 0  
  
Valeurs NaN avant: 9  
Valeurs NaN après: 0
```

FIGURE 3.5 – Nettoyage des données

— **Standardisation des données des données (StandardScaler)**

Après le nettoyage, une étape de normalisation a été appliquée aux variables numériques à l'aide de la méthode *StandardScaler*. Cette technique consiste à centrer les données autour de la moyenne et à les réduire en fonction de leur écart-type, de sorte que chaque variable présente une moyenne nulle et une variance unitaire

La figure 3.6 illustre un exemple de l'application de la standardisation.

```
✓ Normalisation StandardScaler appliquée  
- Moyenne Train: -0.0000  
- Std Train: 1.0003
```

FIGURE 3.6 – Normalisation des données

- **Application de SMOTE** : SMOTE (Synthetic Minority Oversampling Technique) est une technique statistique permettant d'augmenter le nombre de cas d'un jeu de données de façon équilibrée. Le composant fonctionne par génération de nouvelles instances à partir de cas minoritaires fournis en entrée. Cette implémentation de SMOTE ne modifie pas le nombre de cas majoritaires.[16]

Dans le cadre de la modélisation supervisée, les données présentent un déséquilibre important entre les classes, avec une majorité de transactions normales par rapport aux transactions suspectes. Comme illustré dans la figure 3.7, avant l'application de SMOTE, la classe majoritaire (0) contient 1762 observations contre seulement 224 pour la classe minoritaire (1).

Afin de remédier à ce déséquilibre, la technique SMOTE (*Synthetic Minority Over-sampling Technique*) a été appliquée. Cette méthode permet de générer artificiellement de nouvelles observations de la classe minoritaire en interpolant entre les points existants.

Après l'application de SMOTE, le nombre d'observations de la classe minoritaire a été augmenté à 528, réduisant ainsi le déséquilibre initial. Cette étape permet d'améliorer la capacité des modèles supervisés à détecter les transactions suspectes, en évitant un biais en faveur de la classe majoritaire.

```
7. APPLICATION SMOTE
-----
AVANT SMOTE:
anomalie
0.0    1762
1.0     224
Name: count, dtype: int64

APRÈS SMOTE:
anomalie
0.0    1762
1.0     528
Name: count, dtype: int64
```

FIGURE 3.7 – Distribution des classes avant et après application de SMOTE

3.3.3 Construction des caractéristiques

Dans cette étape, un processus d'ingénierie des caractéristiques a été réalisé afin de transformer les données transactionnelles brutes du fichier `opérations_comptes` en un ensemble de variables comportementales agrégées par compte. Cette transformation permet de passer d'un niveau transactionnel à un niveau analytique exploitable par les modèles de machine learning.

Par exemple plusieurs caractéristiques statistiques ont été construites à partir de la variable `montant`, telles que le nombre de transactions, le montant total, la moyenne, la médiane, l'écart-type, ainsi que les valeurs minimale et maximale.

La figure 3.8 illustre un exemple des caractéristiques générées à partir des montants transactionnels, mettant en évidence la transformation des données brutes en variables synthétiques pertinentes pour la détection des comportements anormaux.

```

#FEATURES DE BASE (MONTANTS)
# =====

print("\n2. FEATURES DE BASE")
print("-"*80)

features = operations.groupby('compte').agg(
    nb_transactions=('montant', 'count'),
    total_montant=('montant', 'sum'),
    montant_moyen=('montant', 'mean'),
    montant_median=('montant', 'median'),
    montant_std=('montant', 'std'),
    montant_min=('montant', 'min'),
    montant_max=('montant', 'max'),
    date_min=('date_operation', 'min'),
    date_max=('date_operation', 'max')
).reset_index()

# Durée activité
features['duree_activite_jours'] = (
    features['date_max'] - features['date_min']
).dt.days + 1

# Ratio max/moyen
features['ratio_max_moyen'] = features['montant_max'] / features['montant_moyen']

print(f"✓ Features de base créées: {features.shape}")

```

FIGURE 3.8 – Exemple des caractéristiques

3.3.4 Sélection des caractéristiques

Cette étape vise à identifier et retenir les caractéristiques les plus pertinentes pour améliorer la détection des transactions suspectes, en réduisant la dimensionnalité des données et en éliminant les variables peu informatives. Elle prépare les données optimisées pour la modélisation selon le paradigme d'apprentissage utilisé.

Méthodes de sélection Deux approches distinctes ont été adoptées selon le type d'apprentissage :

1. Mutual Information (apprentissage supervisé)


La *Mutual Information* (MI) mesure la dépendance statistique entre chaque caractéristique et la variable cible **anomalie**. Contrairement à la corrélation de Pearson, qui ne capture que les relations linéaires, la MI quantifie toute forme de dépendance, y compris les relations non linéaires particulièrement fréquentes dans les comportements transactionnels suspects. Pour chaque feature X_i , le score MI est défini par :

$$I(X_i; Y) = \sum_{x,y} p(x, y) \log \frac{p(x, y)}{p(x) p(y)}$$

où Y représente la variable cible (0 = normal, 1 = suspect). Un score nul indique une indépendance totale avec la cible, tandis qu'un score élevé traduit une forte contribution informationnelle. Afin de déterminer le seuil optimal

de sélection, plusieurs valeurs ont été testées dans l'intervalle $[0.01, 0.20]$, et le seuil maximisant le ROC AUC d'un Random Forest proxy a été retenu. Cette métrique est privilégiée à l'accuracy en raison du fort déséquilibre des classes caractéristique de la détection de fraude.

La figure 3.9 illustre le nombre de variables sélectionnées en fonction du seuil de sélection basé sur l'information mutuelle (MI).



1.	temps_min_entre_tx_min	(MI: 0.2438)
2.	temps_median_entre_tx_min	(MI: 0.2147)
3.	tx_par_jour	(MI: 0.1813)
4.	nb_transactions_mois	(MI: 0.1720)
5.	temps_moyen_entre_tx_min	(MI: 0.1476)
6.	changements_lieu_frequents	(MI: 0.1111)
7.	ratio_montant_max_min	(MI: 0.1063)
8.	total_montant	(MI: 0.1026)
9.	ratio_max_moyen	(MI: 0.1008)
10.	montant_std	(MI: 0.0984)
11.	nb_transactions	(MI: 0.0958)
12.	velocite_maximale_km_h	(MI: 0.0949)
13.	montant_max	(MI: 0.0917)
14.	montant_min	(MI: 0.0696)
15.	montant_moyen	(MI: 0.0681)
16.	montants_croissants_consecutifs	(MI: 0.0680)
17.	pct_lieu_principal	(MI: 0.0349)
18.	nb_tpe_moins_100	(MI: 0.0338)
19.	montant_median	(MI: 0.0324)

FIGURE 3.9 – Sélection par MI

Toutefois, la MI ne garantit pas l'absence de redondance entre les variables retenues. En effet, des features comme `montant_moyen`, `montant_médian` et `montant_std`, ou encore `temps_moyen_entre_tx` et `temps_médian_entre_tx`, peuvent présenter des scores MI élevés tout en étant fortement corrélées entre elles, sans apporter d'information complémentaire au modèle.

Pour remédier à cela, un filtre de corrélation a été appliqué en seconde étape : toute variable dont la corrélation de Pearson avec une autre variable déjà retenue dépasse un seuil $\rho = 0.85$ est éliminée, en conservant celle ayant le score MI le plus élevé.

La figure 3.10 illustre le nombre de variables sélectionnées à l'issue de l'étape basée sur l'information mutuelle (MI), ainsi que le nombre de variables restantes après l'application du filtre de corrélation.

```

VARIABLES FINALES APRÈS FILTRE CORRÉLATION (seuil=0.85) :
-----
1. temps_min_entre_tx_min      (MI: 0.2438)
2. temps_median_entre_tx_min  (MI: 0.2147)
3. tx_par_jour                 (MI: 0.1813)
4. nb_transactions_mois       (MI: 0.1720)
5. changements_lieu_frequents (MI: 0.1111)
6. ratio_montant_max_min      (MI: 0.1063)
7. total_montant               (MI: 0.1026)
8. ratio_max_moyen            (MI: 0.1008)
9. montant_std                (MI: 0.0984)
10. nb_transactions            (MI: 0.0958)
11. vitesse_maximale_km_h     (MI: 0.0949)
12. montant_min               (MI: 0.0696)
13. montant_moyen             (MI: 0.0681)
14. montants_croissants_consecutifs (MI: 0.0680)
15. pct_lieu_principal        (MI: 0.0349)
16. nb_tpe_moins_100         (MI: 0.0338)

19 → 16 variables (3 supprimées : ['temps_moyen_entre_tx_min', 'montant_max', 'montant_median'])

```

FIGURE 3.10 – Nombre de variables sélectionnées par MI avant et après filtrage de corrélation

2. VarianceThreshold (apprentissage non supervisé)

Dans le cadre non supervisé, aucune variable cible n'est disponible pour guider la sélection. La méthode *VarianceThreshold* a donc été adoptée : elle élimine les caractéristiques dont la variance est inférieure à un seuil θ , selon le critère :

$$\text{Var}(X_i) = \frac{1}{n} \sum_{j=1}^n (x_{ij} - \bar{x}_i)^2 < \theta$$

Une feature à faible variance est quasi-constante sur l'ensemble des comptes et n'apporte donc aucune information discriminante pour détecter des comportements atypiques. Cette approche est particulièrement adaptée aux features agrégées issues de `features_comptes`, où certaines variables peuvent présenter peu de variabilité inter-comptes.

Justification du choix des méthodes : Il est important de souligner que le choix de deux méthodes distinctes n'est pas arbitraire. La *Mutual Information* requiert obligatoirement une variable cible pour quantifier la dépendance entre chaque feature et la classe à prédire, ce qui la rend applicable uniquement dans le cadre supervisé. En revanche, dans le cadre non supervisé, aucune étiquette n'est disponible, ce qui rend la MI inapplicable. Le *VarianceThreshold* a donc été retenu comme alternative naturelle, car il repose uniquement sur la distribution des données sans nécessiter de variable cible.

3.4 Conclusion

Ce chapitre a permis de poser les bases analytiques du projet en explorant et en préparant les données transactionnelles de la BH Bank. L'analyse exploratoire a mis en évidence des comportements atypiques significatifs, notamment des vitesses de déplacement impossibles, des délais très courts entre transactions et

des montants extrêmes, confirmant la pertinence des données pour la détection d'anomalies. Grâce aux étapes de nettoyage, de normalisation et de feature engineering, un jeu de données structuré de 25 caractéristiques comportementales a été construit, constituant une base solide pour l'application des algorithmes de machine learning dans le chapitre suivant.

Chapitre 4 : Modélisation

4.1 Introduction

Dans ce chapitre, nous présentons la phase de modélisation et de déploiement de la solution proposée pour la détection des anomalies dans les transactions bancaires. Cette étape constitue le cœur du processus analytique, permettant de transformer les données préparées en modèles prédictifs capables d'identifier des comportements suspects.

Afin de répondre efficacement à la problématique, plusieurs approches d'apprentissage ont été explorées. Tout d'abord, des méthodes d'apprentissage supervisé ont été mises en œuvre en exploitant les données labellisées disponibles. Ensuite, des techniques d'apprentissage non supervisé ont été utilisées afin de détecter des anomalies sans dépendre explicitement des étiquettes. Par ailleurs, des approches semi-supervisées ont également été étudiées pour tirer parti à la fois des données labellisées et non labellisées, ce qui est particulièrement pertinent dans un contexte de déséquilibre des classes.

En complément de ces méthodes classiques, des modèles basés sur le deep learning ont été intégrés afin de capturer des relations complexes et non linéaires au sein des données transactionnelles. Ces approches permettent d'améliorer la capacité de détection face à des schémas de fraude évolutifs et difficiles à modéliser.

Enfin, la solution retenue a été intégrée dans une logique de déploiement, incluant l'exploitation de modèles de type LLM pour l'analyse et l'interrogation de documents, afin d'enrichir l'interprétation des résultats et faciliter l'accès à l'information.

4.2 Modélisation

La phase de modélisation consiste à développer, entraîner et évaluer différents modèles d'apprentissage automatique afin d'extraire des connaissances pertinentes et d'optimiser la performance du système.

4.2.1 Approche supervisée

Dans l'apprentissage supervisé, les modèles sont entraînés à l'aide de données étiquetées, où chaque entrée est associée à une sortie connue. Le modèle apprend en comparant ses prédictions à ces réponses correctes et en réduisant itérativement l'erreur.

Au cœur de ce processus se trouvent les modèles d'apprentissage automatique qui apprennent les relations explicites entre les caractéristiques et les résultats. La présence de données étiquetées fournit des directives claires, rendant l'apprentissage supervisé bien adapté aux problèmes où la précision, la traçabilité et la répétabilité sont essentielles.[17]

Dans ce contexte, la variable cible utilisée pour l'apprentissage supervisé représente l'anomalie. Celle-ci a été construite sur la base de règles métier préalablement

définies et soigneusement validées par l'encadrant professionnel, garantissant ainsi la fiabilité des étiquettes.




FIGURE 4.1 – Schéma de l'approche supervisée pour la classification des transactions bancaires

- Modèles supervisés

1. **Random Forest** : Le Random Forest, ou forêt aléatoire, est un algorithme d'apprentissage supervisé incontournable. Il a été introduit au début des années 2000 par Leo Breiman et Adele Cutler, comme une extension de la technique des arbres de décision, déjà bien établie dans le domaine du Machine Learning. Pour améliorer les performances de prédiction, Breiman a proposé l'idée d'utiliser un ensemble d'arbres de décision aléatoires. Cette méthode permettait de tirer parti de la diversité des arbres et d'atténuer les effets du surajustement. En introduisant le concept de diversité par le biais d'échantillons aléatoires et de sous-ensembles de fonctionnalités, Breiman a réussi à créer un algorithme robuste et performant. Le Random Forest est ainsi capable de gérer de grands ensembles de données complexes. Les Random Forests combinent plusieurs arbres de décision. Les techniques d'entraînement qui leur sont appliquées améliorent la précision de prédiction finale et réduisent le surajustement. Ils produisent néanmoins des résultats plus complexes.[18]

Dans le cadre de la détection de fraudes bancaires, Random Forest est particulièrement utile pour sa capacité à gérer des relations complexes et non linéaires entre les variables. Il offre également une mesure de l'importance des variables, permettant d'identifier les caractéristiques les plus pertinentes.

Dans le cadre de ce projet, les hyperparamètres du Random Forest ont été optimisés à l'aide de la technique **GridSearchCV**[19], permettant d'explorer systématiquement les meilleures combinaisons de paramètres. Les paramètres soumis à cette optimisation sont les suivants :

- **n_estimators** : nombre d'arbres de décision construits dans la forêt.
- **max_depth** : profondeur maximale de chaque arbre de décision.
- **min_samples_split** : nombre minimal d'échantillons requis pour diviser un nœud interne.
- **min_samples_leaf** : nombre minimal d'échantillons requis dans une feuille terminale.
- **class_weight** : ajustement des poids des classes afin de compenser le déséquilibre entre transactions normales et suspectes.

2. **Logistic Regression** : La régression logistique, ou le modèle Logit est une technique d'analyse statistique et de Machine Learning utilisée pour modéliser la relation entre une variable dépendante binaire et un ensemble de variables indépendantes. Elle repose sur une fonction mathématique appelée fonction logistique ou sigmoïde qui prend en compte la somme pondérée des variables indépendantes. Celle-ci transforme la somme pondérée en une valeur entre 0 et 1, interprétée comme la probabilité que la variable dépendante soit égale à 1. En d'autres termes, la régression logistique permet de modéliser la probabilité que l'événement d'intérêt se produise en fonction des variables explicatives.[20]

Dans le contexte bancaire, la régression logistique est pertinente pour identifier des schémas frauduleux récurrents en attribuant une probabilité de fraude à chaque transaction. Sa rapidité d'exécution et sa robustesse en font une solution adaptée aux bases de données de grande taille.

Dans le cadre de ce projet, les hyperparamètres de la Régression Logistique ont été optimisés à l'aide de la technique **GridSearchCV**. Les paramètres soumis à cette optimisation sont les suivants :

- **C** : paramètre de régularisation contrôlant le compromis entre la complexité du modèle et l'ajustement aux données d'entraînement.
- **penalty** : type de régularisation appliquée au modèle (L1, L2 ou elasticnet), permettant de réduire le surajustement.
- **solver** : algorithme d'optimisation utilisé pour minimiser la fonction de coût.
- **max_iter** : nombre maximal d'itérations accordées au solveur pour converger.
- **class_weight** : ajustement des poids des classes afin de compenser le déséquilibre entre transactions normales et suspectes.

3. **XGBoost** : XGBoost, ou Extreme Gradient Boosting, est une bibliothèque logicielle distribuée hautement optimisée, conçue pour mettre en œuvre des algorithmes d'apprentissage automatique dans le cadre du Gradient Boos-

ting. Reconnu pour son efficacité, sa flexibilité et sa portabilité exceptionnelles, XGBoost est devenu le choix privilégié des scientifiques des données travaillant avec des données structurées ou tabulaires.

L'efficacité de XGBoost réside dans l'optimisation de son système et dans les améliorations apportées à ses algorithmes. Contrairement aux techniques de bagging telles que Random Forest, qui construisent des arbres indépendamment, XGBoost construit des arbres de manière séquentielle. Chaque nouvel arbre tente de minimiser les erreurs (résidus) des précédents. Pour éviter que le modèle ne devienne trop complexe et ne mémorise le bruit dans les données d'entraînement, XGBoost intègre à la fois des termes de régularisation L1 (Lasso) et L2 (Ridge) dans sa fonction objective. Cette protection intégrée contre le surajustement est un facteur clé de différenciation qui garantit des performances robustes sur des données inconnues.[21]

Dans le domaine de la détection des fraudes bancaires, XGBoost est reconnu pour ses performances élevées, en particulier dans des contextes où les classes sont déséquilibrées. Il permet de capturer efficacement les interactions complexes entre les variables et offre une grande flexibilité.

Dans le cadre de ce projet, les hyperparamètres de XGBoost ont été optimisés à l'aide de la technique **GridSearchCV**. Les paramètres soumis à cette optimisation sont les suivants :

- **n_estimators** : nombre d'arbres construits séquentiellement lors du processus de boosting.
- **max_depth** : profondeur maximale de chaque arbre, contrôlant la complexité du modèle.
- **learning_rate** : taux d'apprentissage régulant la contribution de chaque arbre au modèle final.
- **subsample** : fraction des échantillons utilisée pour l'entraînement de chaque arbre, réduisant le risque de surajustement.
- **colsample_bytree** : fraction des variables sélectionnées aléatoirement pour la construction de chaque arbre.
- **reg_alpha** : terme de régularisation L1 (Lasso) pénalisant les coefficients du modèle.
- **reg_lambda** : terme de régularisation L2 (Ridge) contrôlant la complexité globale du modèle.
- **scale_pos_weight** : paramètre d'ajustement du déséquilibre entre les classes, favorisant la détection des transactions suspectes minoritaires.

4. **KNN** : L'algorithme des k plus proches voisins (KNN) est un classificateur d'apprentissage non paramétrique et supervisé qui s'appuie sur la notion de proximité pour réaliser des classifications ou des prédictions sur le regroupement d'un point de données. Il s'agit de l'une des méthodes de classification et de régression les plus simples et les plus utilisées actuellement dans le machine learning.[22]

En détection de fraude, l'algorithme KNN se révèle pertinent car il permet d'identifier les transactions atypiques en se basant sur leur éloignement par rapport à leurs voisins les plus proches. Il est particulièrement efficace lorsque les données présentent une structure sous forme de regroupements naturels, permettant de distinguer plus facilement les transactions normales des transactions frauduleuses.

Dans le cadre de ce projet, les hyperparamètres de KNN ont été optimisés à l'aide de la technique **GridSearchCV**. Les paramètres soumis à cette optimisation sont les suivants :

- **n.neighbors** : nombre de voisins pris en compte pour la classification, paramètre central influençant directement la sensibilité du modèle aux anomalies.
- **weights** : méthode de pondération des voisins, permettant d'accorder plus d'importance aux voisins les plus proches lors de la classification.
- **metric** : mesure de distance utilisée pour calculer la proximité entre les transactions (euclidienne, Manhattan, etc.).
- **algorithm** : algorithme de recherche des voisins les plus proches (ball_tree, kd_tree ou brute force).
- **p** : paramètre de la distance de Minkowski, généralisant les distances euclidienne et Manhattan.

5. **Decision Tree** : Un arbre de décisions est un algorithme d'apprentissage supervisé non paramétrique, utilisé à la fois pour les tâches de classification et de régression. Il possède une structure hiérarchique et arborescente, qui se compose d'un nœud racine, de branches, de nœuds internes et de nœuds feuille.[23]

Ce modèle est particulièrement pertinent dans le contexte bancaire en raison de sa simplicité d'interprétation. Il permet de comprendre aisément les mécanismes et les règles qui conduisent à classer une transaction comme frauduleuse.

Dans le cadre de ce projet, les hyperparamètres du Decision Tree ont été optimisés à l'aide de la technique **GridSearchCV**. Les paramètres soumis à cette optimisation sont les suivants :

- **max_depth** : profondeur maximale de l'arbre, limitant sa complexité et réduisant le risque de surajustement.
- **min_samples_split** : nombre minimal d'échantillons requis pour diviser un nœud interne.
- **min_samples_leaf** : nombre minimal d'échantillons requis dans une feuille terminale, évitant une segmentation trop fine des données.
- **criterion** : fonction de mesure de la qualité d'une division, telle que l'impureté de Gini ou l'entropie.
- **class_weight** : ajustement des poids des classes afin de compenser le déséquilibre entre transactions normales et suspectes.

6. **SVM** : Les SVM sont couramment utilisées dans les problèmes de classification. Elles distinguent deux classes en trouvant l'hyperplan optimal qui

maximise la marge entre les points de données les plus proches des classes opposées. Le nombre de fonctionnalités dans les données d'entrée détermine si l'hyperplan est une ligne dans un espace à 2 dimensions ou un plan dans un espace à n dimensions. Étant donné que plusieurs hyperplans peuvent être trouvés pour différencier les classes, l'optimisation de la marge entre les points permet à l'algorithme de trouver la meilleure limite de décision entre les classes. Ceci lui permet de bien généraliser à de nouvelles données et de faire des prédictions de classification précises.[24] Le modèle SVM est

particulièrement adapté à la détection des transactions suspectes grâce à sa capacité à séparer efficacement les données en construisant une frontière de décision optimale entre les classes. Il est notamment performant dans des espaces de grande dimension et permet de capturer des relations complexes entre les variables. Dans le contexte bancaire, le SVM est utile pour distinguer les transactions normales des transactions frauduleuses, même lorsque les différences sont subtiles, ce qui en fait un outil pertinent pour améliorer la précision de la détection.

Dans le cadre de ce projet, les hyperparamètres du SVM ont été optimisés à l'aide de la technique **GridSearchCV**. Les paramètres soumis à cette optimisation sont les suivants :

- **C** : paramètre de régularisation contrôlant le compromis entre la maximisation de la marge et la minimisation des erreurs de classification.
- **kernel** : fonction noyau définissant la transformation de l'espace des données (linéaire, RBF, polynomial, sigmoïde), permettant de capturer des relations non linéaires entre les variables transactionnelles.
- **gamma** : paramètre de la fonction noyau RBF contrôlant l'influence de chaque point d'entraînement sur la frontière de décision.
- **degree** : degré du polynôme utilisé lorsque le noyau polynomial est sélectionné.
- **class_weight** : ajustement des poids des classes afin de compenser le déséquilibre entre transactions normales et suspectes.

7. **Naive Bayes** : L'algorithme Naive Bayes est un classificateur probabiliste basé sur le théorème de Bayes, qui suppose une indépendance conditionnelle entre les variables explicatives. Malgré cette hypothèse simplificatrice, il s'avère efficace dans de nombreux problèmes de classification, notamment lorsque les données sont de grande dimension. Il calcule la probabilité d'appartenance d'une observation à chaque classe et attribue la classe dont la probabilité a posteriori est la plus élevée. Dans le contexte bancaire, Naive

Bayes présente l'avantage d'être rapide et peu coûteux en termes de calcul, ce qui le rend adapté au traitement de grands volumes de transactions. Il fournit directement des scores de probabilité de suspicion, facilitant ainsi l'interprétation des alertes par les analystes.

Contrairement aux autres modèles retenus dans ce projet, **GaussianNB** ne nécessite pas d'optimisation par **GridSearchCV**. En effet, le modèle suppose que les variables suivent une distribution gaussienne au sein de chaque

classe, ce qui lui permet d'estimer directement les probabilités de suspicion sans nécessiter de phase de tuning. Par ailleurs, son unique hyperparamètre ajustable (`var_smoothing`) n'a qu'un impact marginal sur les performances. Naive Bayes est donc utilisé dans sa configuration par défaut et joue le rôle de **modèle de référence probabiliste (baseline)**, permettant d'évaluer et de mettre en valeur les gains de performance apportés par les modèles plus complexes et optimisés.

-Sélection des modèles supervisés : La sélection des modèles supervisés utilisés pour la détection des anomalies transactionnelles a été effectuée après une analyse approfondie des approches reconnues dans la littérature scientifique. Les critères retenus pour ce choix sont les suivants :

- La pertinence dans une approche supervisée, reposant sur l'exploitation de données étiquetées permettant de distinguer clairement les transactions suspectes des transactions normales.
- La capacité de classification, garantissant des résultats fiables dans un contexte de données transactionnelles déséquilibrées.
- La robustesse et la capacité de généralisation, afin d'assurer une performance stable face à la diversité des comportements frauduleux.
- La complémentarité des approches, en combinant des modèles d'interprétabilité différente pour couvrir un large spectre de comportements atypiques.

Sur cette base, un ensemble de modèles supervisés a été retenu, comme présenté dans la partie précédente. Random Forest et XGBoost ont été sélectionnés pour leur robustesse et leur efficacité sur des données déséquilibrées. Le modèle SVM est adapté à la séparation des classes dans des espaces de grande dimension, tandis que Decision Tree est privilégié pour son interprétabilité. La régression logistique a été utilisée comme modèle de référence en raison de sa simplicité. KNN repose sur la similarité entre les observations, alors que Naive Bayes a été intégré comme modèle probabiliste de base pour la comparaison des performances.

4.2.1.1 Métriques d'évaluation des modèles supervisés

Les métriques utilisées pour évaluer les modèles dans une approche supervisée sont des indicateurs standards pour mesurer la performance de la classification, notamment pour distinguer les transactions suspectes des transactions normales. Dans ce qui suit, nous présentons les principales métriques adoptées et leur pertinence dans notre contexte.

- **Précision**

La précision mesure la proportion de transactions prédites comme suspectes qui sont réellement anormales. Elle est particulièrement utile lorsque l'on souhaite limiter les fausses alertes (faux positifs).

$$Précision = \frac{TP}{TP + FP}$$

où :

- *TP* (Vrais Positifs) : Nombre de transactions correctement identifiées comme suspectes.

Ce sont les cas où le modèle a correctement prédit la classe positive. En d'autres termes, à la fois l'étiquette prédite et l'étiquette réelle sont positives.[25]

- *FP* (Faux Positifs) : Nombre de transactions normales incorrectement classées comme suspectes.

Ce sont les cas où le modèle a incorrectement prédit la classe positive alors que la classe réelle était négative. Cela est également connu sous le nom d'erreur de type I ou de fausse alarme.[25]

— **Rappel (Recall)**

Le rappel mesure la proportion d'anomalies correctement détectées parmi toutes les anomalies réelles. Il est critique dans notre contexte afin de ne manquer aucune transaction suspecte.

$$Rappel = \frac{TP}{TP + FN}$$

où :

- *FN* (Faux Négatifs) : nombre d'anomalies non détectées (faux négatifs).

Le modèle a incorrectement prédit un résultat négatif, c'est-à-dire que le résultat réel était positif. Cela est également connu sous le nom d'erreur de type II.[26]

— **F1-Score**

Le F1-Score combine la précision et le rappel pour fournir une mesure unique qui équilibre les deux aspects. Il est particulièrement adapté aux datasets déséquilibrés, caractéristiques des données transactionnelles bancaires.

$$F1 = \frac{2 \times Précision \times Rappel}{Précision + Rappel}$$

— **ROC-AUC (Receiver Operating Characteristic - Area Under Curve)**

Le ROC-AUC mesure la capacité du modèle à distinguer les transactions suspectes des transactions normales sur l'ensemble des seuils de décision possibles. Une valeur proche de 1 indique une excellente capacité de discrimination.

$$AUC = \int_0^1 TPR(FPR) dFPR$$

où :

- $TPR = Rappel = \frac{TP}{TP + FN}$ (True Positive Rate)
- $FPR = \frac{FP}{FP + TN}$ (False Positive Rate)
- *TN* : nombre de transactions normales correctement classées.

Le modèle a correctement prédit un résultat négatif, c'est-à-dire que le résultat réel était négatif.[26]

4.2.1.2 Score composite des modèles supervisés

Le score composite est un indicateur global conçu pour classer et sélectionner le modèle supervisé le plus performant. Il combine de manière pondérée plusieurs métriques d'évaluation afin d'obtenir une mesure équilibrée des performances, en tenant compte à la fois de la capacité de détection et de la robustesse du modèle. Le choix des coefficients est justifié par le contexte métier bancaire : le rappel est prioritaire car manquer une transaction suspecte est bien plus coûteux qu'une fausse alerte[27], tandis que le ROC-AUC reflète la performance globale sur des données déséquilibrées[28].

Le score composite est défini comme suit :

$$ScoreComposite = 0.40 \cdot Recall + 0.35 \cdot ROC - AUC + 0.15 \cdot F1 + 0.10 \cdot Précision$$

où :

- **Recall** (0.40) : priorité maximale afin de minimiser les anomalies non détectées, dont le coût est le plus élevé dans le contexte bancaire.
- **ROC-AUC** (0.35) : reflète la performance globale du modèle sur l'ensemble des seuils de décision, particulièrement pertinent sur des données déséquilibrées.
- **F1-Score** (0.15) : assure un équilibre entre la détection des anomalies et la limitation des fausses alertes.
- **Précision** (0.10) : contribue à réduire les fausses alertes, moins critique que le rappel dans notre contexte.

Les métriques étant déjà comprises entre 0 et 1, elles contribuent directement au score sans nécessiter de normalisation supplémentaire. Le modèle obtenant le score composite le plus élevé est retenu comme la solution la plus performante pour la détection des anomalies transactionnelles.

4.2.1.3 Résultats de l'évaluation des modèles supervisés

TABLE 4.1 – Comparaison des modèles supervisés selon les métriques et le score composite

#	Modèle	ROC-AUC	Precision	Recall	F1-Score	Score Composite
1	XGBoost	0.9952	0.9462	0.9167	0.9312	0.9493
2	Random Forest	0.9964	0.9667	0.9063	0.9355	0.9482
3	SVM	0.9885	0.8878	0.9063	0.8969	0.9318
4	Logistic Regression	0.9853	0.8788	0.9063	0.8923	0.9291
5	Decision Tree	0.9859	0.9231	0.8750	0.8984	0.9221
6	KNN	0.9794	0.8989	0.8333	0.8649	0.8957
7	Naive Bayes	0.9525	0.7327	0.7708	0.7513	0.8277

Les résultats montrent que le modèle **XGBoost** obtient le meilleur score composite, malgré un score ROC-AUC légèrement inférieur à celui de Random Forest. Cette performance s'explique par un **Recall plus élevé**, critère prioritaire dans le contexte de la détection des transactions suspectes, où le coût des anomalies non détectées est particulièrement élevé. Ainsi, en tenant compte des contraintes métier et de la pondération des métriques, **XGBoost est retenu comme le modèle le plus performant**.

4.2.1.4 Interprétabilité du modèle XGBoost avec SHAP

Les valeurs SHAP sont un moyen courant d'obtenir une explication cohérente et objective de l'impact de chaque caractéristique sur la prédiction du modèle.

Les valeurs SHAP sont basées sur la théorie des jeux et attribuent une valeur d'importance à chaque caractéristique d'un modèle. Les caractéristiques ayant des valeurs SHAP positives ont un impact positif sur la prédiction, tandis que celles ayant des valeurs négatives ont un impact négatif. L'ampleur est une mesure de l'importance de l'effet. [29]

Importance globale (SHAP) : La figure 4.2 illustre l'importance globale des variables du modèle **XGBoost** à l'aide des valeurs SHAP. Cette représentation met en évidence la contribution moyenne de chaque caractéristique à la prédiction du modèle, en se basant sur la moyenne des valeurs absolues des scores SHAP. On observe que la variable `tx_par_jour` est la plus influente, suivie par `nb_transactions_mois` et `total_montant`, ce qui indique que la fréquence et le volume des transactions jouent un rôle déterminant dans la détection des comportements suspects. Cette analyse globale permet ainsi d'identifier les variables les plus discriminantes et d'interpréter le modèle de manière agrégée.




FIGURE 4.2 – Importance globale des variables avec SHAP

SHAP Waterfall : La figure 4.3 illustre une explication locale de la prédiction du modèle **XGBoost** à travers un graphique de type SHAP Waterfall[30]. Cette visualisation détaille l’impact de chaque variable sur une prédiction individuelle, en partant d’une valeur de base moyenne pour atteindre la sortie finale du modèle. Les contributions positives (en rouge) augmentent la probabilité que le compte soit suspect, tandis que les contributions négatives (en bleu) la réduisent. Dans cet exemple, des variables telles que `tx_par_jour` et `vitesse_maximale_km_h` contribuent fortement à augmenter le score de suspicion, alors que d’autres variables atténuent cette décision. Ce type d’analyse permet de comprendre précisément pourquoi une transaction ou un compte a été classé comme suspect ou normal, renforçant ainsi la transparence du modèle.




FIGURE 4.3 – Explication locale avec SHAP Waterfal

4.2.2 Approche non supervisée

L'apprentissage non supervisé, également connu sous le nom de machine learning non supervisé, utilise des algorithmes de machine learning (ML) pour analyser et regrouper des jeux de données non étiquetées. Ces algorithmes découvrent des modèles ou des groupes de données cachés sans intervention humaine[31]




FIGURE 4.4 – Approche non supervisée

1. Modèles non supervisés

- **K-means** : K-means ou K-moyennes est l'un des algorithmes le plus simple et le plus populaire, notamment en Machine Learning et en statistiques. Il permet de classer un dataset en clusters en fonction de leurs similarités, selon un nombre prédéfini de regroupements, représenté par la lettre K.

L'algorithme de clustering K-means est un élément essentiel pour la découverte de groupes au sein de données non catégorisées. Son objectif principal est de partitionner un ensemble de données en K clusters. Chacun contient un ensemble de points de données similaires.

Il cherche également à minimiser la variance intracluster, en créant des groupes compacts et homogènes. Il s'agit de regrouper les points de données similaires afin que la somme des carrés des distances entre chaque point et le centroïde du cluster soit minimale.[32]

Dans le cadre de la suspicion des fraudes bancaires, K-Means se révèle particulièrement adapté en raison de sa simplicité et de son efficacité pour regrouper les transactions normales en clusters principaux, tandis que les transactions suspectes apparaissent comme des points isolés ou constituent de petits groupes distincts.

Afin d'optimiser le modèle K-Means, plusieurs valeurs du nombre de clusters k ont été testées, ainsi que différents seuils de filtrage de variance (VT). Chaque configuration a été évaluée à l'aide des métriques de silhouette, de Davies-Bouldin et de Calinski-Harabasz. Le choix final des hyperparamètres repose principalement sur la maximisation du score de silhouette, tout en assurant une bonne séparation et compacité des clusters, dans le but d'iden-

tifier efficacement les comportements suspects.

La figure 4.5 présente une projection des données transactionnelles dans un espace bidimensionnel obtenu à l'aide de l'Analyse en Composantes Principales (PCA), appliquée après le clustering par K-Means. Les deux premières composantes principales expliquent une part importante de la variance totale des données, permettant une visualisation pertinente de leur structure.

On observe que les transactions normales (en bleu), associées aux clusters principaux identifiés par K-Means, forment un noyau dense et relativement homogène. En revanche, les transactions suspectes (en rouge), identifiées sur la base de leur distance élevée aux centroïdes, apparaissent plus dispersées et souvent éloignées des groupes principaux.

Certaines observations suspectes sont clairement isolées, ce qui confirme leur caractère atypique, tandis que d'autres se situent en périphérie des clusters, illustrant des cas plus ambigus. Cette représentation met en évidence la capacité de K-Means à modéliser les comportements normaux et à détecter les transactions suspectes comme des points éloignés ou faiblement intégrés aux clusters.




FIGURE 4.5 – Projection PCA 2D des résultats K-Means

— Isolation Forest :

L'isolation forest (moins connu sous son nom français « forêt d'isolement ») calcule un score d'anomalie pour chaque observation du dataset. Ce score donne une mesure de la normalité de chaque observation en fonction de l'ensemble des données. Pour calculer ce score, l'algorithme isole la donnée en question de manière récursive : il choisit une variable au hasard et fixe un seuil de coupure au hasard, puis il évalue si cela permet d'isoler une observation en particulier.[33]

Ce modèle a été retenu pour sa capacité à traiter efficacement de grands

volumes de données et à identifier des transactions suspectes caractérisées par des comportements rares ou isolés, tels que des montants inhabituels ou des fréquences anormales.

Les hyperparamètres, notamment *contamination* (proportion estimée d'anomalies) et *max_samples* (taille de l'échantillon utilisé pour chaque arbre), ont été ajustés afin d'optimiser les performances du modèle.

La figure 4.6 présente la distribution des scores d'anomalie générés par le modèle Isolation Forest. Les scores négatifs, représentés en rouge, correspondent aux comptes détectés comme suspects, tandis que les scores positifs, en bleu, correspondent aux comptes normaux. La ligne pointillée orange matérialise le seuil de décision à zéro, au-delà duquel un compte est considéré comme normal. On observe que la majorité des comptes présentent des scores élevés, confirmant le faible taux d'anomalies détectées cohérent avec le paramètre de contamination fixé à 0.01.




FIGURE 4.6 – Scores d'anomalie obtenus par Isolation Forest

— One-Class SVM :

One-Class SVM est un algorithme qui apprend une frontière autour des données normales afin de distinguer les observations atypiques. Il projette les données dans un espace de plus grande dimension à l'aide d'un noyau, puis estime une frontière englobant la majorité des points normaux. Les transactions situées en dehors de cette frontière sont considérées comme suspectes.

Ce modèle a été sélectionné pour sa capacité à détecter des anomalies subtiles dans les transactions bancaires, telles que des comportements légèrement

déviant par rapport aux habitudes normales.

Les hyperparamètres, tels que ν (proportion maximale d'anomalies) et γ (paramètre du noyau), ont été ajustés afin d'assurer une détection fiable des comportements suspects.

La figure 4.7 présente la distribution des scores de décision du modèle One-Class SVM (paramètre $\nu = 0.02$). L'axe des abscisses représente le score de décision, où les valeurs négatives indiquent les comptes détectés comme anomalies et les valeurs positives les comptes normaux. La frontière de décision est fixée à $score = 0$ (ligne pointillée noire).




FIGURE 4.7 – Distribution des scores de décision du modèle One-Class SVM

— Local Outlier Factor (LOF) :

Le Local Outlier Factor (LOF) est une méthode de détection d'anomalies basée sur la densité locale des données. Il compare la densité d'un point à celle de ses voisins les plus proches afin d'identifier les observations atypiques, caractérisées par une densité significativement plus faible.

Ce modèle est particulièrement adapté à la détection de comportements suspects locaux, notamment dans des environnements où les anomalies ne sont pas globalement isolées mais diffèrent uniquement de leur voisinage immédiat.

Les hyperparamètres, tels que $n_neighbors$ (nombre de voisins) et $contamination$, ont été ajustés afin d'obtenir un compromis optimal entre sensibilité et précision dans la détection des transactions suspectes.

Le modèle LOF dans la figure 4.8 (PCA=2, $k = 30$ voisins) classe environ 2700 comptes comme normaux contre une centaine de comptes suspects, soit un taux d'anomalies d'environ 3%, cohérent avec le paramètre de contami-

nation fixé.




FIGURE 4.8 – Répartition des comptes normaux et suspects

- **Brich** : BIRCH signifie Balanced Iterative Hierarchical Based Clustering (groupement hiérarchique itératif équilibré). Il est utilisé sur de très grands ensembles de données pour lesquels K-Means ne peut pas s'adapter de manière pratique. L'algorithme BIRCH divise les données volumineuses en petits groupes et tente de conserver le maximum d'informations possible. Les petits groupes sont ensuite regroupés pour obtenir un résultat final au lieu de regrouper directement les grands ensembles de données. [34]

Ce modèle a été retenu pour sa scalabilité et sa capacité à traiter de grands volumes de transactions bancaires, en identifiant les transactions suspectes comme des observations atypiques, soit sous forme de clusters distincts, soit comme des points isolés.

Le modèle BIRCH ($n_clusters = 2$) détecte 86 comptes suspects dont la distance au centroïde dépasse le seuil $P97 = 4.10$ (ligne pointillée orange). La courbe bleue montre une progression régulière des distances pour les comptes normaux, tandis que les anomalies (en rouge) présentent une montée abrupte au-delà du seuil, traduisant leur éloignement marqué par rapport au centre de leur cluster.




FIGURE 4.9 – Distribution des distances au centroïde

Optimisation des hyperparamètres et réduction de dimension : L'ensemble des hyperparamètres des modèles — notamment le nombre de clusters k , le facteur de contamination, le nombre de voisins $k_neighbors$ ainsi que les seuils de variance — a été déterminé à l'aide d'une recherche en grille (*grid search*). Pour chaque configuration, trois métriques d'évaluation non supervisées ont été calculées : le score de Silhouette, l'indice de Davies-Bouldin (DB) et l'indice de Calinski-Harabasz (CH). La configuration optimale est celle qui maximise le score de Silhouette, assurant une bonne séparation entre les observations normales et les observations suspectes.

Par ailleurs, une réduction de dimension par Analyse en composantes principales (PCA) a été appliquée uniquement aux modèles K-Means et LOF, en raison de leur sensibilité à la dimensionnalité et aux corrélations entre variables. Cette étape a permis d'améliorer légèrement la qualité du clustering en réduisant le bruit et en facilitant la structure des données.

2. Sélection des modèles non supervisés :

La sélection des modèles utilisés pour la détection des anomalies transactionnelles bancaires a été réalisée après une analyse approfondie des travaux scientifiques portant sur ce domaine. Les critères de choix ont inclus :

- L'adaptabilité à une approche non supervisée, compte tenu de l'absence de données étiquetées fiables dans le contexte bancaire tunisien, où les fraudes confirmées sont rares et difficilement accessibles.
- La capacité à identifier des comportements transactionnels atypiques sans connaissance préalable des patterns frauduleux, permettant ainsi la découverte

d'anomalies émergentes.

- La complémentarité des approches, en combinant des méthodes basées sur la densité, l'isolation et la frontière de décision afin de couvrir une large variété de comportements suspects.
- La robustesse et la pertinence démontrées dans des études antérieures appliquées à la détection d'anomalies dans des données financières et bancaires.

Ainsi, les modèles présentés précédemment, à savoir K-Means, BIRCH, Local Outlier Factor (LOF), Isolation Forest et One-Class SVM, ont été retenus pour la phase de modélisation en raison de leurs caractéristiques complémentaires et de leur efficacité dans les tâches de détection d'anomalies.

4.2.2.1 Métriques d'évaluation des modèles non supervisés

Les métriques utilisées pour évaluer les modèles non supervisés sont des indicateurs standards permettant de mesurer la qualité des clusters ou des détections d'anomalies. Dans ce qui suit, nous présentons les principales métriques adoptées et leur pertinence dans notre contexte de détection d'anomalies bancaires :

- **Silhouette score** : évalue la cohésion et la séparation des clusters en calculant, pour chaque point de données, la différence entre la distance moyenne aux points du même cluster et la distance moyenne au cluster le plus proche. Sa valeur varie entre -1 et 1 , où un score élevé (proche de 1) indique des clusters bien définis et séparés, idéal pour distinguer les comptes bancaires normaux des comptes suspects dans notre scénario de détection de fraude.

Le score de Silhouette est défini comme :

$$s = \frac{b - a}{\max(a, b)} \quad (1)$$

où a et b représentent respectivement la distance intra-cluster moyenne et la distance moyenne au cluster le plus proche. Plus précisément, a désigne la distance moyenne entre un échantillon et tous les autres échantillons appartenant au même cluster, calculée pour l'ensemble des clusters, tandis que b désigne la distance moyenne entre un échantillon et tous les autres échantillons du cluster voisin le plus proche, calculée pour l'ensemble des échantillons et des clusters.[35]

- **Calinski-Harabasz score** : également connu sous le nom de *Variance Ratio Criterion*, mesure le ratio entre la dispersion inter-cluster (séparation) et intra-cluster (cohésion). Une valeur plus élevée signifie des clusters compacts et bien espacés, ce qui aide à identifier des groupes d'anomalies claires parmi les comportements transactionnels suspects.

La formule du Calinski-Harabasz score est la suivante :

$$\beta = \frac{\text{tr}(B_k)}{\text{tr}(W_k)} \cdot \frac{N - k}{k - 1} \quad (2)$$

où k est le nombre de clusters et N désigne le nombre total d'échantillons dans le jeu de données. B_k et W_k sont donnés par :

$$B_k = \sum_{q=1}^k n_q (c_q - c_E)(c_q - c_E)^T \quad (3)$$

$$W_k = \sum_{q=1}^k \sum_{x \in C_q} (x - c_q)(x - c_q)^T \quad (4)$$

où C_q est l'ensemble des points du q -ième cluster, c_q désigne le centre du cluster q , c_E indique le centre du jeu de données, et n_q est le nombre de points dans le cluster q . [35]

- **Davies-Bouldin score** : calcule la moyenne des similarités entre chaque cluster et son plus proche voisin. Une valeur faible (proche de 0) reflète une bonne partition des données, car elle indique des clusters distincts et peu similaires, facilitant la détection des comptes suspects sans chevauchement excessif avec les comportements normaux.

Le score de Davies-Bouldin est défini comme :

$$\gamma = \frac{1}{k} \sum_{i=1}^k \max_{i \neq j} R_{ij} \quad (5)$$

où k est le nombre de clusters, et R_{ij} est donné par :

$$R_{ij} = \frac{s_i + s_j}{d_{i,j}} \quad (6)$$

où s_i est la distance moyenne entre chaque point du cluster i et le centroïde de ce cluster, et $d_{i,j}$ est la distance entre les centroïdes des clusters i et j . Des scores élevés indiquent des clusters plus proches les uns des autres et plus dispersés. [35]

4.2.2.2 Score composite pour les modèles non supervisés

Afin de sélectionner automatiquement le modèle le plus performant parmi les cinq modèles non supervisés évalués (K-Means, BIRCH, Isolation Forest, LOF et One-Class SVM), un score composite est calculé en combinant les trois métriques d'évaluation présentées précédemment. Ce score est défini comme suit :

$$ScoreComposite = \frac{1}{3} \times \frac{S+1}{2} + \frac{1}{3} \times \frac{CH}{1+CH} + \frac{1}{3} \times \frac{1}{1+DB} \quad (7)$$

où S , CH et DB désignent respectivement le Silhouette score, le Calinski-Harabasz score et le Davies-Bouldin score.

Chaque terme de cette formule repose sur une normalisation mathématique intrinsèque garantissant que toutes les métriques contribuent dans l'intervalle $[0, 1]$, indépendamment de l'échelle des données :

latex

- Le Silhouette score étant naturellement borné dans $[-1, 1]$, cette transformation le ramène dans $[0, 1]$ de façon linéaire, pénalisant les scores négatifs qui traduisent une mauvaise séparation des clusters.
- Le score de Calinski-Harabasz étant strictement positif et non borné, cette transformation de type sigmoïde le comprime dans $[0, 1[$, croissant rapidement pour les petites valeurs et saturant progressivement pour les grandes, ce qui évite qu'un modèle monopolise le score composite par un CH anormalement élevé.
- Le score de Davies-Bouldin étant positif et non borné, avec une valeur faible reflétant une meilleure partition, cette transformation l'inverse et le borne dans $[0, 1]$, pénalisant ainsi les mauvaises séparations inter-clusters.

4.2.2.3 Résultats de la sélection par score composite

Les résultats des évaluations basées sur le score composite sont présentés dans le tableau 4.2 suivant, calculé pour chaque modèle à partir des trois métriques normalisées :

TABLE 4.2 – Tableau de comparaison des métriques pour les modèles non supervisés

#	Modèle	Silhouette	Davies-Bouldin	Calinski-Harabasz	Score Composite
1	K-Means	0.5307	0.6926	4865.7	0.7853
2	BIRCH	0.5035	0.7915	459.1	0.7693
3	Isolation Forest	0.4826	1.3833	89.5	0.7166
4	One-Class SVM	0.3369	2.9926	38.3	0.6312
5	LOF	0.1633	6.1535	12.9	0.5498

-Interprétation :

Les scores montrent que **K-Means** se distingue avec un score composite de **0.7853**, reflétant une excellente cohésion et séparation des clusters (Silhouette de 0.5307, indice Calinski-Harabasz très élevé à 4865.7, et Davies-Bouldin faible à 0.6926).

BIRCH offre également de bons résultats avec un score composite de 0.7693, grâce à des valeurs de Silhouette et Davies-Bouldin proches de celles de K-Means. Cependant, son indice Calinski-Harabasz nettement inférieur (459.1 contre 4865.7) témoigne d'une densité inter-cluster moins prononcée.

En revanche, **Isolation Forest**, **One-Class SVM** et **LOF** affichent des performances inférieures. Isolation Forest obtient un score de 0.7166, pénalisé par un Davies-Bouldin de 1.3833 et un Calinski-Harabasz de seulement 89.5. One-Class SVM (0.6312) et LOF (0.5498) présentent les performances les plus faibles, avec des indices Davies-Bouldin très élevés (respectivement 2.9926 et 6.1535), indiquant un chevauchement important entre les clusters normaux et suspects.

Ainsi, **K-Means est sélectionné comme le modèle le plus performant** pour ce scénario de détection de transactions bancaires suspectes, grâce à sa combinaison optimale des trois métriques d'évaluation normalisées.

4.2.3 Modèles de Deep Learning

Le deep learning est un type de machine learning qui utilise des réseaux de neurones artificiels pour apprendre à partir de données, de la même manière que nous apprenons. Les réseaux de neurones artificiels s'inspirent du cerveau humain et peuvent être utilisés pour résoudre une grande variété de problèmes, y compris la reconnaissance d'image, le traitement du langage naturel et la reconnaissance vocale.

Les algorithmes de deep learning sont généralement entraînés sur de grands ensembles de données étiquetées. Les algorithmes apprennent à associer les caractéristiques

présentes dans les données aux étiquettes appropriées.[36]

4.2.3.1 Choix des modèles de Deep Learning

Dans le cadre de ce travail, deux modèles de deep learning ont été sélectionnés pour la détection de transactions bancaires suspectes : **TabNet** et **l'Autoencodeur**. Ce choix repose sur des critères complémentaires liés à la nature des données, aux contraintes du problème et aux objectifs de détection.

1. **Tabnet** : Tabnet est un package d'apprentissage profond sur les données tabulaires d'après Tabnet Arik and Pfister (2019). Il est entièrement basé sur torch et donc sans installation de python et s'intègre dans la suite tidymodels.[37] Les raisons de ce choix sont les suivantes :
 - **Données tabulaires** : notre dataset est composé de 25 features numériques extraites des transactions bancaires, ce qui correspond exactement au domaine d'application de TabNet.
 - **Apprentissage supervisé** : les labels d'anomalie étant disponibles, TabNet peut exploiter directement cette information pour apprendre la frontière de décision entre comptes normaux et suspects.
 - **Interprétabilité** : le mécanisme d'attention de TabNet produit des scores d'importance par feature, offrant une explication native des décisions du modèle — un critère essentiel dans le domaine bancaire où la traçabilité des décisions est réglementairement exigée.
 - **Gestion du déséquilibre** : TabNet supporte nativement la pondération des classes via le paramètre `weights`, ce qui est particulièrement adapté à notre dataset déséquilibré .

La figure 4.10 illustre l'évolution de l'AUC sur l'ensemble de validation au cours des 20 époques d'entraînement de TabNet.




FIGURE 4.10 – L'évolution de l'AUC sur l'ensemble de validation

- **Convergence rapide** : l'AUC progresse très rapidement lors des premières époques . Cela illustre la capacité de TabNet extraire les patterns discriminants dès les premières itérations.

- **Performance finale** : l'AUC atteint une valeur maximale de **0.9911** à l'époque 17, avec un AUC final de 0.9631 sur l'ensemble de test, ce qui confirme la qualité du modèle appris.




FIGURE 4.11 – Top 10 des features les plus importantes selon TabNet

Interprétabilité intrinsèque de TabNet : Contrairement aux modèles classiques tels que XGBoost ou Random Forest, dont l'interprétabilité repose sur des méthodes externes comme les valeurs SHAP ou les importances de Gini calculées a posteriori, TabNet intègre nativement un mécanisme d'attention séquentielle qui sélectionne, à chaque étape de décision, les features les plus pertinentes. Les importances présentées ci-dessus 4.11 émergent donc directement du processus d'apprentissage, sans recours à des outils tiers. Cette propriété confère à TabNet un avantage double : la puissance prédictive des réseaux de neurones combinée à une transparence comparable aux modèles interprétables, ce qui est particulièrement précieux dans le contexte de la détection de fraude bancaire où la justification des décisions constitue une exigence opérationnelle et réglementaire.

2. **Autoencodeur** : Les autoencodeurs sont un type particulier de réseau neuronal non supervisé (aucune étiquette n'est nécessaire!). La principale application des autoencodeurs consiste à capturer avec précision les aspects clés des données fournies afin de fournir une version compressée des données d'entrée, de générer des données synthétiques réalistes ou de signaler les anomalies.[38]

L'Autoencoder est un réseau de neurones non supervisé composé d'un **encodeur** qui compresse les données dans un espace latent de dimension réduite, et d'un **décodeur** qui reconstruit les données originales à partir de cet espace. La détection d'anomalies repose sur le principe que le modèle, entraîné uniquement

sur les comportements normaux, ne saura pas bien reconstruire un comportement suspect — ce qui se traduit par une **erreur de reconstruction élevée**.

Les raisons de ce choix sont les suivantes :

- **Approche non supervisée** : l'Autoencoder n'utilise pas les labels pendant l'entraînement, ce qui le rend applicable dans des contextes réels où toutes les anomalies ne sont pas encore étiquetées.
- **Modélisation du comportement normal** : en apprenant exclusivement la distribution des comptes normaux, le modèle développe une représentation compacte du comportement attendu. Tout écart significatif par rapport à cette représentation est interprété comme une anomalie potentielle.
- **Pas besoin de SMOTE** : Dans le cadre de l'Autoencoder, le recours à des techniques de rééchantillonnage telles que SMOTE n'est pas nécessaire. En effet, le modèle est entraîné exclusivement sur les transactions normales afin d'apprendre leur distribution et leur structure latente. Les transactions anormales ne sont pas utilisées durant l'apprentissage mais uniquement lors de la phase d'évaluation, où elles sont détectées à travers l'erreur de reconstruction. Par conséquent, le déséquilibre entre classes n'affecte pas le processus d'entraînement, ce qui rend les méthodes de sur-échantillonnage inadaptées dans ce contexte.




FIGURE 4.12 – Courbe de loss de l'Autoencoder

Analyse de la courbe de loss de l'Autoencoder : La fonction de perte utilisée lors du pré-entraînement de l'Autoencoder mesure l'erreur de reconstruction, c'est-à-dire la capacité du modèle à reproduire en sortie des données les plus proches possible des entrées originales après passage par l'espace latent compressé. Une loss élevée indique que l'Autoencoder n'a pas encore appris une représentation suffisamment fidèle des données, tandis qu'une loss faible reflète une bonne capture des structures sous-jacentes.

D'après la courbe ci-dessus 4.12, la loss décroît rapidement durant les 100 premières époques, passant de 1.0 à environ 0.40, traduisant une acquisition rapide des patterns généraux des transactions. Elle se ralentit ensuite progressivement entre les époques 100 et 200, le modèle affinant sa représentation latente vers des structures plus fines. Une légère perturbation est visible aux alentours de l'époque 200, sans affecter la tendance générale. La loss se stabilise finalement autour de 0.10 après l'époque 250, confirmant la convergence du modèle et validant la qualité du pré-entraînement non supervisé fourni à TabNet.

Justification de la différence du nombre d'époques entre l'Autoencoder et TabNet : Cette disparité s'explique par la nature différente des deux phases d'apprentissage. L'Autoencoder, utilisé en mode non supervisé, vise à reconstruire fidèlement les données d'entrée sans disposer de labels, ce qui nécessite un apprentissage progressif et relativement long (300 époques) afin de capturer les structures latentes des transactions.

En revanche, TabNet bénéficie des représentations apprises par l'Autoencoder grâce à une phase de pré-entraînement, ce qui lui permet de ne pas repartir de zéro. Ainsi, l'apprentissage supervisé (fine-tuning[39]) converge plus rapidement, en seulement 20 époques, le modèle se contentant d'adapter des caractéristiques déjà pertinentes à la tâche spécifique de détection de transactions suspectes.

4.2.4 Synthèse comparative des trois approches de modélisation

Les différentes approches de modélisation évaluées dans ce projet ont permis d'analyser les comportements transactionnels suspects selon plusieurs perspectives complémentaires.

- **Approche supervisée :** Les modèles supervisés ont obtenu les meilleures performances globales, ce qui s'explique directement par la disponibilité des labels générés en amont par les règles métier définies en collaboration avec les experts de la BH Bank. En effet, c'est grâce à ces étiquettes construites à partir de critères métier précis — tels que la vitesse géographique, la fréquence transactionnelle nocturne ou les montants atypiques — que les modèles supervisés ont pu apprendre à distinguer les comptes normaux des comptes suspects, sans recourir à une annotation manuelle exhaustive. XGBoost s'est distingué par un ROC AUC de 0.9952 et un recall de 0.9167, permettant de détecter la majorité des comptes suspects. Bien que Random Forest ait obtenu un ROC AUC légèrement supérieur (0.9964), XGBoost a été retenu comme modèle final en raison de son meilleur recall, critère prioritaire dans

un contexte bancaire où la non-détection d'une anomalie peut engendrer des risques financiers et réglementaires importants.

- **Approche non supervisée :** Les modèles non supervisés ont joué un rôle essentiel dans l'identification initiale des comportements atypiques en absence de données étiquetées. K-Means a obtenu les meilleurs résultats avec un score de Silhouette de 0.5307, traduisant une séparation satisfaisante entre les profils transactionnels. Cette approche permet de détecter des anomalies émergentes et de s'adapter à l'évolution des comportements frauduleux sans intervention humaine directe.
- **Approche Deep Learning :** Les modèles de deep learning, bien que présentant des performances légèrement inférieures à l'approche supervisée, jouent un rôle complémentaire essentiel dans un contexte bancaire. Contrairement aux modèles supervisés classiques qui nécessitent une sélection de features manuelle et un rééchantillonnage explicite par SMOTE, les modèles de deep learning apprennent directement à partir des données brutes en extrayant automatiquement les représentations pertinentes grâce à leurs couches profondes. Cette capacité d'apprentissage automatique des représentations les rend particulièrement adaptés à des données transactionnelles complexes et de grande dimension. TabNet se distingue particulièrement par son mécanisme d'attention séquentielle qui sélectionne nativement les features les plus pertinentes à chaque étape de décision, offrant ainsi une interprétabilité intrinsèque précieuse pour la justification des alertes auprès des analystes et des régulateurs bancaires. Dans un environnement soumis à des exigences croissantes de transparence et de conformité réglementaire, cette capacité d'explication des décisions constitue un atout majeur que les modèles supervisés classiques ne peuvent fournir qu'à travers des outils externes tels que SHAP.

Meilleure approche retenue : L'approche supervisée avec **XGBoost** constitue la meilleure solution de production car elle combine le recall le plus élevé (0.9167), une robustesse prouvée sur des données déséquilibrées, et une interprétabilité assurée par SHAP — répondant simultanément aux exigences de performance et de conformité réglementaire de la BH Bank.

4.3 Conclusion

La phase de modélisation a permis d'explorer différentes approches d'apprentissage, incluant des méthodes supervisées, non supervisées ainsi que des techniques issues du deep learning, afin de détecter les comportements anormaux dans les transactions bancaires. Plusieurs modèles ont été entraînés et évalués selon des critères de performance adaptés au déséquilibre des classes. Cette étape a abouti à la sélection du modèle le plus performant et le plus pertinent pour la détection des transactions suspectes, en tenant compte à la fois de la précision, du rappel et de la robustesse face aux données réelles.

Chapitre 5 : Déploiement de la solution

5.1 Introduction

Le déploiement constitue la phase finale de la méthodologie CRISP-DM. les résultats du projet sont présentés aux parties prenantes et sont intégrés si nécessaire dans les systèmes existants pour aider la prise de décision. Cette phase implique souvent la création de rapports, de visualisations ou d'autres formes de communication pour rendre les résultats compréhensibles et utilisables par ceux qui ne seraient pas spécialistes des données.[40]

Dans le cadre de ce projet, cette étape vise à concrétiser l'ensemble des travaux réalisés — notamment le feature engineering, la modélisation non supervisée ainsi que la classification supervisée — au sein d'une application web interactive, cohérente et fonctionnelle.

L'objectif principal de cette phase est de proposer un système complet de détection des transactions suspectes. Ce système permet à un analyste bancaire de soumettre les transactions associées à un compte et d'obtenir une prédiction automatique basée sur le modèle XGBoost préalablement entraîné.

En complément, un assistant conversationnel (chatbot) est intégré à la plateforme afin de faciliter l'accès à l'information. Contrairement au module de prédiction, ce chatbot a un rôle purement informatif : il permet de communiquer des explications générales concernant la détection des anomalies, d'apporter des éclaircissements sur les notions de fraude, et de guider l'utilisateur dans la compréhension des résultats fournis par le système, sans intervenir directement dans le processus de décision.

L'ensemble du système repose sur une architecture unifiée, exposant toutes les fonctionnalités à travers une interface web développée avec le framework Flask, garantissant ainsi simplicité d'utilisation, interactivité et efficacité opérationnelle.

5.2 Technologies et outils utilisés

Le développement de la solution s'appuie sur un ensemble de technologies complémentaires, choisies pour leur adéquation avec les besoins fonctionnels et techniques du système. L'ensemble a été implémenté dans l'environnement de développement **Visual Studio Code**, offrant une intégration efficace des différents composants.

- **Flask** : utilisé comme framework backend pour la gestion des routes, des requêtes HTTP et l'intégration des différents modules applicatifs.
- **Scikit-learn et Joblib** : utilisés pour le chargement des modèles et des objets de prétraitement, assurant leur exploitation en phase de prédiction.
- **LangChain et ChromaDB** : utilisés pour la mise en œuvre du module RAG, permettant l'indexation et la recherche contextuelle dans une base de connaissances vectorielle.
- **HuggingFace** : utilisé pour la génération d'embeddings textuels via un modèle multilingue adapté.
- **Groq** : utilisé pour l'accès à un modèle de langage avancé via API, assurant la génération des réponses du chatbot.

- **Vosk et FFmpeg** : utilisés pour la reconnaissance vocale, permettant la conversion et le traitement des flux audio.
- **HTML5, CSS3, JavaScript et Jinja2** : utilisés pour le développement de l'interface utilisateur, assurant une interaction fluide et une présentation claire des résultats.

5.3 Analyse fonctionnelle des pages de l'interface web

L'interface web du système est organisée en cinq pages principales, chacune dédiée à un ensemble de fonctionnalités spécifiques. L'ensemble des pages partagent une structure commune définie dans un template de base, comprenant une barre de navigation fixe permettant de naviguer entre les différentes sections de l'application, ainsi qu'un pied de page récapitulatif. Cette architecture de templates garantit une cohérence visuelle et une expérience utilisateur homogène sur l'ensemble du système.

5.3.1 Page d'accueil

La page d'accueil constitue le point d'entrée de l'application. Elle présente le contexte général du projet à travers une section héro mettant en valeur l'objectif principal du système, à savoir la détection des transactions suspectes en temps réel.

La Figure 5.1 illustre l'interface de la page d'accueil de l'application.



FIGURE 5.1 – Page d'accueil de l'application

La page présente également les trois modules principaux du système — la simulation, le chatbot et le dashboard analytique — accompagnés de descriptions synthétiques et de liens de navigation directs. L'objectif de cette page est de fournir une vue d'ensemble claire du projet et de guider l'utilisateur vers les fonctionnalités adaptées à ses besoins.

Comme le montre la Figure 5.2, la page d'accueil met en avant les principaux modules du système afin de faciliter l'accès rapide aux différentes fonctionnalités.




FIGURE 5.2 – Interface des principales fonctionnalités de la page d'accueil

5.3.2 Page de simulation

La page de simulation constitue le module central du système de détection. Elle permet à un analyste bancaire de soumettre les transactions d'un compte bancaire et d'obtenir une prédiction automatique quant au caractère suspect ou normal du comportement transactionnel observé. Le processus de simulation repose sur deux étapes distinctes et successives : la saisie des transactions et l'analyse par le modèle de machine learning.

La page propose deux modes d'alimentation en données, accessibles via deux onglets distincts de l'interface.

- Le premier mode est la **saisie manuelle**. L'analyste renseigne les transactions du compte une par une, en fournissant pour chacune le montant en dinars tunisiens, le sens de l'opération (débit ou crédit), la date et l'heure exactes, le lieu géographique et le type d'opération (virement, paiement par terminal de paiement électronique...). Ce mode est adapté aux cas de test ciblés portant sur un nombre réduit de transactions, permettant à l'analyste de construire manuellement un scénario transactionnel précis.

Comme illustré dans la Figure 5.3, l'utilisateur peut saisir les informations d'une transaction via un formulaire structuré, puis lancer l'analyse afin d'obtenir une évaluation du comportement du compte.

The screenshot shows the 'Simulation' page of the 'Détection des Transactions Suspectes' application. The page has a dark blue header with navigation links: Accueil, Simulation (active), ChatBot, Dashboard, and À propos. The main content area is split into two panels.

Transactions du compte (1 transaction(s))

Número de compte: 14010123110699001111

Options: Saisie manuelle (selected), Importer un fichier

TRANSACTION #1

Montant (DT): 500, Sens: Débit

Date & heure: 04/29/2026 07:42 PM, Lieu: Tunis

Type d'opération: Virement (VIR), Motif détail (optionnel): ex: VIR.TN M. KHALIL

+ Ajouter une transaction

Analyser le compte

Résultat de l'analyse

Compte 14010123110699001111 – 1 transaction(s) analysée(s)

Normal (Prédiction XGBoost (modèle supervisé))

% NOCTURNE	% WEEK-END
0.0%	0.0%
VÉLOCITÉ MAX	RATIO TRE <100DT
0 km/h	0.0%
MONTANT MOYEN	LIEUX DIFFÉRENTS
500 DT	1

✓ Aucun scénario suspect détecté – comportement transactionnel normal.

FIGURE 5.3 – Saisie manuelle de transactions d'un compte

- Le second mode est l'**import de fichier**. L'analyste charge un fichier au format CSV ou Excel contenant l'historique complet des transactions d'un compte. Le fichier est lu intégralement par le système sans que les transactions individuelles ne soient affichées dans l'interface, ce qui rend ce mode particulièrement adapté aux situations réelles où l'analyste dispose d'un historique de plusieurs dizaines de transactions. Une confirmation visuelle indique le nombre de transactions chargées et le nom du fichier importé.

Les figures ci-dessous 5.4 , 5.5 illustrent le fonctionnement du mode import de fichier de la page de simulation, depuis le chargement du fichier jusqu'à l'affichage du résultat de l'analyse avec les scénarios suspects déclenchés par le modèle XGBoost.




FIGURE 5.4 – Interface de la page de simulation en mode import de fichier




FIGURE 5.5 – Résultat de l'analyse après import du fichier

Analyse par le modèle XGBoost : Une fois les transactions soumises, le système procède automatiquement au calcul des variables comportementales agrégées à partir des données brutes fournies. Ces variables sont identiques aux caractéristiques construites

lors de la phase de préparation des données, garantissant ainsi une cohérence totale entre l'environnement d'entraînement et l'environnement de production.

Le vecteur de caractéristiques ainsi obtenu est normalisé à l'aide du **StandardScaler** ajusté lors de la phase d'entraînement, puis soumis au modèle **XGBoost** chargé en mémoire depuis le fichier sérialisé. Le modèle traite le compte soumis comme un nouvel exemple de test, à l'image des données utilisées lors de la phase d'évaluation. Ses paramètres étant figés depuis l'entraînement sur les 2839 comptes historiques, il applique les patterns appris pour produire une décision sans se ré-entraîner ni intégrer le nouveau compte à sa base de connaissance. Il s'agit d'une pure phase d'inférence : le modèle consulte ses arbres de décision construits lors de l'entraînement, chaque arbre émet un vote, et l'agrégation de l'ensemble de ces votes détermine la décision finale, à savoir **Normal** ou **Suspect**.

5.3.3 Page Chatbot

La page du chatbot met à disposition de l'utilisateur un assistant conversationnel spécialisé dans la détection des transactions suspectes ainsi que dans les concepts du domaine bancaire. Cet assistant repose sur une architecture de génération augmentée par récupération, connue sous l'acronyme **RAG** (*Retrieval-Augmented Generation*)[41].

Cette approche permet de produire des réponses pertinentes en s'appuyant principalement sur une base de connaissances spécifique au projet, plutôt que sur les seules connaissances générales du modèle de langage. Ainsi, les réponses générées sont contextualisées, fiables et adaptées au cadre applicatif étudié.

Pipeline RAG : Le fonctionnement du système RAG s'articule en deux phases distinctes et successives.

La première phase est la phase d'**indexation**, réalisée une seule fois en amont du déploiement. Le document de base de connaissances du projet est découpé en fragments de texte appelés *chunks*, d'une taille de cinq cents caractères avec un chevauchement de cinquante caractères entre fragments consécutifs afin de préserver la continuité du contexte.

Chaque fragment est ensuite transformé en un vecteur numérique de haute dimension appelé *embedding* à l'aide d'un modèle multilingue de type MiniLM[42]. Ce modèle permet de représenter le sens sémantique du texte, notamment en langue française. L'ensemble de ces vecteurs est ensuite stocké dans la base vectorielle **ChromaDB**, qui constitue la mémoire documentaire du système.

La seconde phase est la phase de **génération**, déclenchée à chaque question posée par l'utilisateur. Elle se déroule en trois étapes successives :

1. **Récupération (Retrieval)** : la question de l'utilisateur est transformée en vecteur par le même modèle d'embeddings utilisé lors de l'indexation. ChromaDB calcule la similarité cosinus entre ce vecteur et l'ensemble des fragments indexés, puis retourne les trois fragments les plus pertinents sémantiquement.
2. **Construction du contexte** : les fragments récupérés sont assemblés en un contexte documentaire structuré, auquel est joint l'historique des échanges précédents de la conversation. Cet historique, limité aux cinq derniers tours, permet au

modèle de langage de prendre en compte le fil conversationnel et de répondre à des questions de reformulation ou de précision sans perdre le contexte établi.

3. **Génération (Generation)** : le contexte documentaire, l'historique conversationnel et la question de l'utilisateur sont injectés dans un prompt structuré, transmis au modèle de langage **LLaMA 3.3-70b**[43] via l'API Groq[44]. Le modèle génère une réponse en français, fondée exclusivement sur le contenu documentaire fourni. Si la réponse ne figure pas dans les fragments récupérés, le système l'indique explicitement à l'utilisateur.

Interface et modalités d'interaction : L'interface du chatbot propose les fonctionnalités suivantes :

- **Saisie textuelle** : l'utilisateur formule sa question par écrit via une zone de saisie dédiée.
- **Reconnaissance vocale** : un bouton microphone permet de dicter la question. Le flux audio est capturé, puis transcrit en texte par **Vosk**[45] en mode hors-ligne. Le texte obtenu est ensuite automatiquement soumis comme question.
- **Questions suggérées** : un panneau latéral propose une sélection de questions prédéfinies couvrant les thématiques principales du projet, accessibles en un seul clic.

La figure 5.6 illustre le fonctionnement du chatbot en mode textuel. L'utilisateur peut saisir directement sa question dans le champ prévu à cet effet, puis l'envoyer pour obtenir une réponse instantanée.




FIGURE 5.6 – Interface du chatbot en mode texte

Les figures 5.7 , 5.8 présentent le fonctionnement du chatbot en mode vocal. L'utilisateur peut activer le microphone pour poser sa question oralement.




FIGURE 5.7 – Activation du mode vocal du chatbot




FIGURE 5.8 – Réponse du chatbot après interaction vocale

5.3.4 Page du dashboard

La page du dashboard intègre le rapport d'analyse exploratoire des données développé sous **Power BI** et publié sur Power BI Service. Ce rapport est intégré directement dans l'interface web via un iframe, permettant à l'utilisateur d'accéder aux visualisations interactives sans quitter l'application, comme l'illustre la figure ci-dessus 5.9.




FIGURE 5.9 – Analyse exploratoire des données par PowerBI

5.4 Conclusion

Ce chapitre a présenté les principales étapes du déploiement de la solution développée pour la détection des transactions suspectes. L'intégration du modèle de prédiction au sein d'une application web interactive a permis de proposer un environnement exploitable regroupant un module de simulation, un tableau de bord analytique ainsi qu'un assistant conversationnel basé sur une architecture RAG. L'ensemble de ces composants permet d'assister efficacement les analystes bancaires dans l'interprétation des comportements transactionnels et le soutien à la prise de décision.

Conclusion Générale et Perspectives

Au terme de ce projet de fin d'études réalisé au sein de la BH Bank, nous avons conçu et développé un système intelligent dédié à la détection des transactions suspectes. En nous appuyant sur la méthodologie CRISP-DM, nous avons suivi une démarche structurée allant de la compréhension du contexte bancaire tunisien et de l'exploration des données transactionnelles, jusqu'à la modélisation et au déploiement d'une solution opérationnelle.

Les travaux réalisés ont permis de construire des caractéristiques comportementales pertinentes à travers le feature engineering, d'exploiter des approches non supervisées pour identifier des profils atypiques en l'absence de labels fiables, puis de comparer plusieurs modèles supervisés. Le modèle XGBoost a été retenu comme solution finale en raison de ses performances élevées, avec une attention particulière portée au Recall afin de limiter les risques de non-détection des comptes suspects.

La phase de déploiement a concrétisé ces résultats à travers le développement d'une application web intégrée. Celle-ci regroupe un module de simulation permettant d'analyser des transactions en temps réel, un tableau de bord analytique interactif pour la visualisation des comportements transactionnels, ainsi qu'un chatbot basé sur une architecture RAG facilitant l'accès aux informations et l'interprétation des anomalies.

Au-delà de l'aspect technique, ce projet met en évidence les enjeux liés à la surveillance transactionnelle dans le secteur bancaire, où la détection précoce des anomalies constitue un élément clé pour la gestion des risques. Plusieurs perspectives d'amélioration peuvent être envisagées, notamment l'intégration de nouvelles données pour un ré-entraînement continu du modèle, ainsi que l'ajout de fonctionnalités telles que les alertes en temps réel ou la génération automatique de rapports.

En définitive, ce travail a permis de développer une solution cohérente, explicable et exploitable, tout en consolidant les compétences en data science et en intelligence artificielle, et en démontrant leur valeur ajoutée dans un contexte bancaire réel.

Références

- [1] Bh bank logo. https://fr.wikipedia.org/wiki/BH_Bank. consulté le 22 mars 2025.
- [2] crisp-dm-methodology. <https://www.sv-europe.com/crisp-dm-methodology/>. consulté le 24 mars 2025.
- [3] Les composantes de l'ia. https://docs.eaqbe.com/fr/project_management/crisp_dm. consulté le 24 mars 2025.
- [4] Approche supervisée. https://fr.wikipedia.org/wiki/Intelligence_artificielle. consulté le 24 mars 2025.
- [5] Approche non supervisée. <https://www.chiny.me/apprentissage-non-supervise-e-xplorer-et-regrouper-les-donnees-sans-supervision-25-23.php>. consulté le 24 mars 2025.
- [6] Présentation d'agile. <https://www.atlassian.com/fr/agile>. consulté le 22 mars 2025.
- [7] Crisp-dm. <https://www.le1817.com/blog/la-methodologie-crisp-dm>. consulté le 22 mars 2025.
- [8] Le skimming bancaire. <https://www.creditmutuel.fr/fr/particuliers/securite/skimming.html>. consulté le 20 mai 2025.
- [9] OpenAI. Réponse générée par chatgpt. ChatGPT, modèle GPT-4, 2025. Réponse obtenue le 05 avril 2025 via <https://chat.openai.com>.
- [10] Anthropic. Réponse générée par claude (ia). Claude.ai, modèle Claude Sonnet, 2025. Réponse obtenue le 10 avril 2025 via <https://claude.ai>.
- [11] Stripe. How machine learning works for payment fraud detection and prevention. <https://stripe.com/fr/resources/more/how-machine-learning-works-for-payment-fraud-detection-and-prevention>, 2024. consulté le 27 mars 2025.
- [12] Mariem Trabelsi. Détection des fraudes bancaires basée sur l'intelligence artificielle. Pfe, ISG Tunis, 2025. Document PDF, non publié.
- [13] Compréhension métier. https://docs.eaqbe.com/fr/project_management/crisp_dm. consulté le 27 mars 2025.
- [14] Analyse exploratoire des données. <https://www.jmp.com/fr/statistics-knowledge-portal/exploratory-data-analysis>. consulté le 27 mars 2025.
- [15] Préparation des données. <https://www.le1817.com/blog/la-methodologie-crisp-dm>. consulté le 27 mars 2025.
- [16] Informations complémentaires sur smote. <https://learn.microsoft.com/fr-fr/azure/machine-learning/component-reference/smote>. consulté le 27 mars 2025.
- [17] Qu'est-ce que l'apprentissage supervisé ? <https://www.databricks.com/fr/blog/supervised-vs-unsupervised-learning>. consulté le 8 avril 2025.
- [18] Qu'est-ce qu'un random forest ? <https://www.nexa.fr/blog/random-forest-en-machine-learning>. consulté le 8 avril 2025.
- [19] Gridsearchcv. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html. consulté le 8 avril 2025.
- [20] Qu'est-ce que la régression logistique ? <https://www.nexa.fr/blog/la-regression-logistique>. consulté le 8 avril 2025.

- [21] Xgboost. <https://www.ultralytics.com/fr/glossary/xgboost>. consulté le 8 avril 2025.
- [22] Knn. <https://www.ibm.com/fr-fr/think/topics/knn>. consulté le 10 avril 2025.
- [23] Decision trees. <https://www.ibm.com/fr-fr/think/topics/decision-trees>. consulté le 10 avril 2025.
- [24] Support vector machine. <https://www.ibm.com/fr-fr/think/topics/support-vector-machine>. consulté le 10 avril 2025.
- [25] Confusion matrix : Tp, fp, tn, fn. <https://www.linkedin.com/pulse/understanding-confusion-matrix-true-positive-false-negative-ahmed-vxw2e/>. consulté le 22 avril 2025.
- [26] Confusion matrix in machine learning. <https://www.geeksforgeeks.org/machine-learning/confusion-matrix-machine-learning/>. consulté le 22 avril 2025.
- [27] Cost-sensitive learning in financial fraud detection. https://www.researchgate.net/publication/393569888_Cost-Sensitive_Learning_in_Financial_Fraud_Detection_Models. consulté le 22 avril 2025.
- [28] Roc et scoring de crédit. <https://www.aefr.eu/fr/article/3683-machine-learning-et-nouvelles-sources-de-donnees-pour-le-scoring-de-credit>. consulté le 22 avril 2025.
- [29] Analyse shap. <https://shap.readthedocs.io/en/latest/>. consulté le 27 avril 2025.
- [30] Shap waterfall. <https://shap.readthedocs.io/en/latest/generated/shap.plots.waterfall.html>. consulté le 27 avril 2025.
- [31] Unsupervised learning. <https://www.ibm.com/fr-fr/think/topics/unsupervised-learning>. consulté le 10 avril 2025.
- [32] K-means. <https://www.nexa.fr/blog/k-means-algorithme>. consulté le 11 avril 2025.
- [33] Isolation forest. <https://www.devoteam.com/fr/expert-view/algorithme-n3-comprendre-lisolation-forest-en-5-min/>. consulté le 12 avril 2025.
- [34] Birch clustering. <https://www.datacamp.com/fr/blog/clustering-in-machine-learning-5-essential-clustering-algorithms>. consulté le 12 avril 2025.
- [35] Métriques non supervisées — energies. <https://www.mdpi.com/1996-1073/17/23/5936>. consulté le 20 mai 2025.
- [36] Deep learning. <https://cloud.google.com/discover/what-is-deep-learning?hl=fr>. consulté le 13 avril 2025.
- [37] Tabnet. <https://rr2023.sciencesconf.org/467705/document>. consulté le 13 avril 2025.
- [38] Autoencoders. <https://www.datacamp.com/fr/tutorial/introduction-to-autoencoders>. consulté le 13 avril 2025.
- [39] Fine-tuning. <https://www.nexa.fr/blog/le-fine-tuning-lart-dameliorer-les-resultats-en-machine-learning>. consulté le 13 avril 2025.
- [40] Déploiement. <https://www.le1817.com/blog/la-methodologie-crisp-dm>. consulté le 23 avril 2025.
- [41] Rag. <https://www.ibm.com/fr-fr/think/topics/retrieval-augmented-generation>. consulté le 26 avril 2025.

- [42] Minilm. <https://www.emergentmind.com/topics/minilm>. consulté le 26 avril 2025.
- [43] Llama. <https://www.datacamp.com/fr/blog/llama-3-3-70b>. consulté le 26 avril 2025.
- [44] Groq. <https://www.eesel.ai/fr/blog/groq>. consulté le 26 avril 2025.
- [45] Vosk. https://www.adelean.com/blog/20220105_fine_tuning_modele_vosk/. consulté le 26 avril 2025.